# Parcours pédagogique : IA Responsable

## Du jeu de données aux conclusions — pas à pas

IA708 — Télécom Paris

2026

# Plan


1. Vue d'ensemble
2. Les données
3. Exploration
4. Préparation
5. Modèle
6. Métriques
7. Équité
8. Interprétabilité
9. Robustesse
10. Synthèse

# Le parcours en 11 étapes

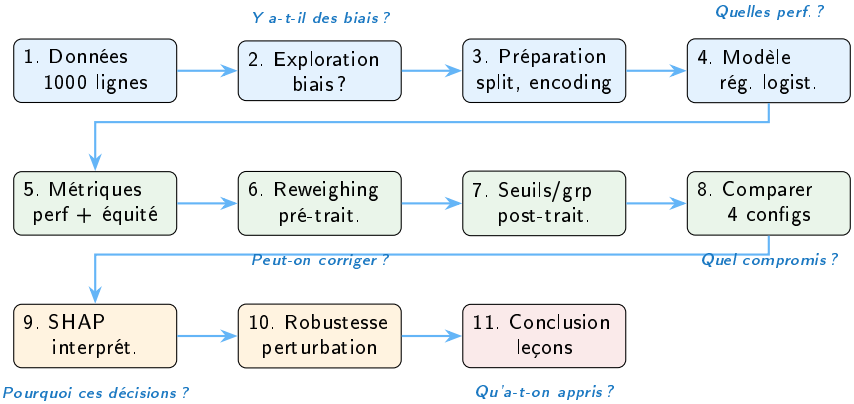


Chaque étape répond à une question qui motive la suivante. Tout codé *from scratch* (numpy/pandas).

# Étape 1 — Le German Credit Dataset

**UCI Statlog** (Hofmann, 1994)

- 1 000 demandes de crédit
- 20 attributs (7 num., 13 cat.)
- Cible : défaut de paiement (0/1)

**Pourquoi ce dataset ?**

- Scoring crédit = décision à fort impact
- Risque de discrimination historique
- Cas d'école en IA responsable

| **Stat** | **Valeur** |
|---|---|
| Bon (0) | 700 (70%) |
| Mauvais (1) | 300 (30%) |
| Numériques | 7 |
| Catégorielles | 13 |

Déséquilibre 70/30 ⇒
accuracy naïve trompeuse

# Étape 2 — Biais préexistants dans les données

**Question** : avant tout modèle, y a-t-il déjà des disparités entre groupes ?

**Genre**

| | Bon | Défaut |
|---|---|---|
| Homme (690) | 72% | 28% |
| Femme (310) | 65% | 35% |

Écart $\approx$ 7 points

**Âge**

| | Bon | Défaut |
|---|---|---|
| Adulte $>$25 (810) | 72% | 28% |
| Jeune $\leq$25 (190) | 60% | 40% |

Écart $\approx$ 12 points

**Conséquence**

Un modèle performant **reproduira** ces disparités historiques. Bonne performance $\neq$ modèle équitable.

# Étape 2 — Deux attributs sensibles

### Genre

- Extrait de `personal_status_sex`
- A91/A93/A94 $\rightarrow$ homme
- A92/A95 $\rightarrow$ femme
- Privilégié : homme

### Âge

- Binarisé au seuil de 25 ans
- Adulte ($> 25$) / jeune ($\leq 25$)
- Privilégié : adulte
- Biais plus marqué (+12 pts)

### Décision de conception

Les deux colonnes sont **retirées des features** $\Rightarrow$ pas de discrimination *directe*.

Mais des **proxies** (features corrélées) peuvent encoder indirectement l'information sensible. À vérifier via SHAP (étape 9).

# Étape 3 — Préparation des données

**Prétraitement**

- **Numériques** (6 col.) : z-score

$$x' = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$$

- **Catégorielles** (12 col.) : one-hot
- Résultat : ∼44 features
- Fit sur train, appliqué au val/test

**Split stratifié 60/20/20**

| | Taille | Rôle |
|---|---|---|
| Train | ∼600 | Entraînement |
| Val | ∼200 | Seuil, PP |
| Test | ∼200 | Éval. finale |

Seed fixé (42) pour reproductibilité. Stratifié : chaque split conserve le ratio 70/30.

**Attention — pas de fuite d'information**

$\mu$ et $\sigma$ calculés **uniquement sur le train** (ddof=1). Les catégories inconnues au val/test sont mises à zéro.

# Étape 4 — Régression logistique from scratch

**Modèle** : $P(\text{défaut} = 1 \mid x) = \sigma(w^\top x + b)$ avec $\sigma(z) = \frac{1}{1+e^{-z}}$

**Entraînement**

- Perte : cross-entropy + L2
- Adam (lr $= 0.03$, $\beta_1 = 0.9$, $\beta_2 = 0.999$)
- Régularisation $\lambda = 0.01$
- Early stopping (patience 300)

**Seuil de décision**

- Pas fixé à 0.5 (déséquilibre !)
- Balayage $\tau \in [0.1,\ 0.9]$
- Maximise la **balanced accuracy** :

$$\text{BalAcc} = \frac{1}{2}(\text{TPR} + \text{TNR})$$

**Perte (avec poids pour le reweighing)**

$$\mathcal{L} = -\frac{1}{n}\sum_i s_i\left[y_i \ln p_i + (1 - y_i)\ln(1 - p_i)\right] + \frac{\lambda}{2}\|w\|^2$$

($s_i = 1$ pour le baseline)

# Étape 5 — Métriques de performance

**Question** : comment évaluer un modèle sur un dataset déséquilibré ?

| **Métrique** | **Pourquoi ?** |
|---|---|
| **AUC ROC** | Invariante au seuil. Capacité à séparer les classes. Calculée par Wilcoxon-Mann-Whitney. |
| **Balanced Acc.** | $\frac{1}{2}(\text{TPR} + \text{TNR})$. Adaptée au déséquilibre (vs accuracy naïve). |
| **ECE** | Expected Calibration Error (cf. cours incertitude). |

**ECE** : $\text{ECE} = \sum_{b=1}^{B} \frac{|B_b|}{n} \left|\text{acc}(B_b) - \text{conf}(B_b)\right|$

Mesure si la confiance du modèle correspond à la réalité. Un modèle bien calibré a ECE $\approx 0$.

# Étape 5 — Métriques d'équité (cf. cours fairness)

Soit $S$ l'attribut sensible, $Y$ la cible, $\hat{Y}$ la prédiction.

| Critère | Définition | Signification |
|---|---|---|
| **Demographic Parity** | $\lvert P(\hat{Y}{=}1 \mid S{=}0) - P(\hat{Y}{=}1 \mid S{=}1)\rvert$ | Même taux de sélection |
| **Equal Opportunity** | $\lvert \mathrm{TPR}_{S=0} - \mathrm{TPR}_{S=1}\rvert$ | Même TPR |

**Évaluation du baseline** (test) :

| | | Sélection | TPR |
|---|---|---|---|
| **Genre** | Homme | $\approx 0.41$ | $\approx 0.70$ |
| | Femme | $\approx 0.50$ | $\approx 0.74$ |
| | $\lvert\Delta\rvert$ | 0.094 | 0.044 |

| | | Sélection | TPR |
|---|---|---|---|
| **Âge** | Adulte | $\approx 0.42$ | $\approx 0.77$ |
| | Jeune | $\approx 0.51$ | $\approx 0.59$ |
| | $\lvert\Delta\rvert$ | 0.081 | **0.179** |

$\Rightarrow$ Le baseline **n'est pas équitable**. $\lvert$EO gap$\rvert$ pour l'âge $= 0.179$ : **correction nécessaire**.

# Étape 6 — Reweighing (pré-traitement)

**Question** : peut-on corriger les biais en repondérant les exemples ?

**Principe** (cf. cours fairness-mitigation) : rendre $S \perp Y$ dans le train.

$$w_i = \frac{P(S{=}s_i) \cdot P(Y{=}y_i)}{P(S{=}s_i,\ Y{=}y_i)}$$

**Intuition** :

- Sous-groupe sous-représenté dans une classe $\Rightarrow$ poids $w > 1$
- Surreprésenté $\Rightarrow$ poids $w < 1$
- On entraîne un **nouveau modèle** avec ces poids
- Un modèle par attribut sensible

| | $Y{=}0$ | $Y{=}1$ |
|---|---|---|
| Privilégié | $w \approx 1$ | $w > 1$ |
| Non-priv. | $w > 1$ | $w \approx 1$ |

Direction typique des poids

# Étape 7 — Seuils par groupe (post-traitement)

**Question** : peut-on corriger **sans ré-entraîner** ?

**Principe** : ajuster le seuil **séparément par groupe** pour égaliser le taux de sélection.

$$\tau_{\text{global}} \to \tau_{g_0}, \tau_{g_1} \quad \text{t.q.} \quad P(\hat{Y}=1|S=g_0) \approx P(\hat{Y}=1|S=g_1)$$

- Seuils calibrés sur la **validation** ($\sim$200 exemples)
- Critère : Demographic Parity

**Avantage**

Pas de ré-entraînement. Même modèle, seul le seuil change.

**Limite**

Peu de données de calibration $\Rightarrow$ seuils potentiellement instables.

# Étape 8 — Comparaison : 4 configurations

| **Attr.** | **Configuration** | **AUC** | **BalAcc** | $\lvert\Delta DP\rvert$ | $\lvert\Delta EO\rvert$ |
|---|---|---|---|---|---|
| Genre | Baseline | 0.793 | 0.701 | 0.094 | 0.044 |
| Genre | Reweighing | 0.793 | 0.701 | 0.094 | 0.044 |
| Genre | Reweighing + PP | 0.793 | 0.727 | 0.238 | 0.192 |
| Âge | Baseline | 0.793 | 0.701 | 0.081 | 0.179 |
| Âge | Reweighing | 0.789 | 0.713 | 0.081 | 0.202 |
| Âge | Reweighing + PP | 0.789 | 0.712 | **0.056** | 0.261 |

**Observations clés :**

- **Genre** : reweighing **sans effet** (lignes identiques) $\Rightarrow$ pas de proxy
- **Âge** : reweighing + PP réduit $\lvert\Delta DP\rvert$ (0.081 $\rightarrow$ **0.056**)
- **Mais** $\lvert\Delta EO\rvert$ augmente (0.179 $\rightarrow$ 0.261) $\Rightarrow$ **compromis**

# Le théorème d'impossibilité en action

**Chouldechova 2017, Kleinberg 2016**

Il est **mathématiquement impossible** de satisfaire simultanément Demographic Parity, Equal Opportunity et calibration, sauf si les taux de base sont égaux entre groupes.

**Ce qu'on observe** :

Pour l'**âge** :

- Réduire $|\Delta DP| \Rightarrow |\Delta EO|$ **augmente**
- $0.081 \rightarrow 0.056$ (DP ✓)
- $0.179 \rightarrow 0.261$ (EO ×)

Ce n'est pas un échec de la méthode — c'est une **limite fondamentale**.

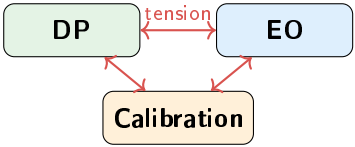


On ne peut pas tout avoir.
Il faut **choisir**.

# Étape 9 — SHAP linéaire exact

**Question** : quelles features déterminent les décisions ?

Pour un modèle linéaire, les **valeurs de Shapley** sont exactes (pas d'approximation) :

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}_{\text{train}}[x_i])$$

**Top 5 features** (baseline) :

1. `checking_status`
2. `duration_in_month`
3. `credit_amount`
4. `credit_history`
5. `savings_account_bonds`

**Importance par permutation**

- Mélanger une colonne → mesurer la **chute d'AUC**
- 10 répétitions par feature
- Méthode complémentaire au SHAP

Les deux méthodes **convergent** sur le classement.

# Étape 9 — Détection de proxies

**Question** : des features encodent-elles **indirectement** le genre ou l'âge ?

Un **proxy** = feature à la fois **corrélée** ($|r| > 0.15$) à $S$ **et influente** (SHAP élevé).

### Genre

- Aucune feature à la fois influente ET corrélée
- **Proxies faibles**
- $\Rightarrow$ Retirer la colonne suffit
- Cohérent : reweighing sans effet

### Âge

- `duration_in_month` : $|r| > 0.15$ + top 2 SHAP
- **Proxy actif**
- $\Rightarrow$ Le modèle "voit" l'âge
- Explique l'effet du reweighing

**Leçon fondamentale**

L'interprétabilité **explique** pourquoi le reweighing fonctionne pour l'âge mais pas pour le genre. Sans SHAP, on ne comprendrait pas.

# Étape 10 — Perturbation et calibration

**Question** : les corrections d'équité fragilisent-elles le modèle ?

**Protocole**

- Num. : $x_j + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0.2 \cdot \sigma_j)$
- Cat. : swap aléatoire ($p$=0.1)

**ECE** (cours incertitude) :

$$\mathrm{ECE} = \sum_b \frac{|B_b|}{n} |\mathrm{acc}_b - \mathrm{conf}_b|$$

Mesure l'écart confiance / réalité.

**Résultats**

| | AUC | BalAcc | ECE |
|---|---|---|---|
| Clean | 0.793 | 0.701 | ∼0.05 |
| Perturbé | ∼0.77 | ∼0.68 | ∼0.06 |
| Δ | −0.02 | −0.02 | +0.01 |

- Corrélation scores : $r \approx 0.97$
- Modèles fair **aussi robustes**

**Conclusion**

Les corrections d'équité **n'amplifient pas la fragilité**. Le modèle linéaire est naturellement robuste.

# Étape 11 — Ce qu'on a appris

1. **Les données sont biaisées** — taux de défaut différents entre groupes. Un bon modèle reproduira ces biais.
2. **Retirer l'attribut sensible ne suffit pas toujours** — genre : oui (proxies faibles). Âge : non (`duration_in_month` = proxy actif).
3. **Le reweighing dépend des proxies** — sans proxy, aucun effet. Avec proxy, le modèle change.
4. **Compromis DP/EO inévitable** — $|\Delta \mathrm{DP}| \downarrow \Rightarrow |\Delta \mathrm{EO}| \uparrow$ (théorème d'impossibilité).
5. **Interprétabilité éclaire l'équité** — SHAP + corrélation = détection de proxies.
6. **Modèle robuste** — $r \approx 0.97$, même après corrections.

# Les trois piliers sont liés

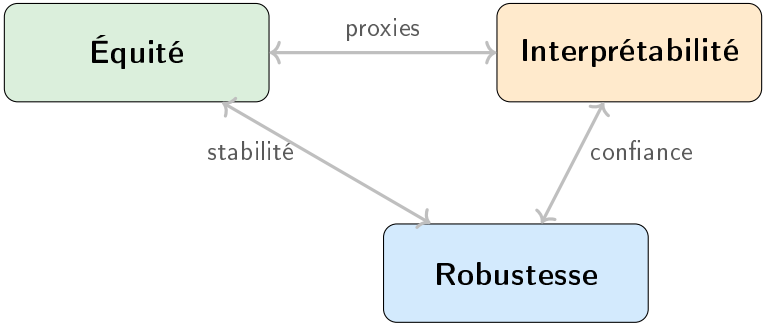


- L'**interprétabilité** révèle les problèmes d'**équité** (proxies)
- La **robustesse** garantit que les corrections d'équité sont **fiables**
- La **confiance** dans le modèle requiert les trois à la fois

*Code from scratch — numpy et pandas uniquement.*