

Parcours pédagogique : IA Responsable

Du jeu de données aux conclusions — explication pas à pas du notebook

IA708 — Télécom Paris, 2026

Résumé

Ce document accompagne le `notebook_simple.ipynb` et détaille chaque étape du parcours d'analyse. L'objectif : évaluer un modèle de scoring crédit sous trois angles — **équité**, **interprétabilité** et **robustesse** — en partant des données brutes et en progressant vers des conclusions argumentées. Tout est codé *from scratch* (numpy/pandas, sans scikit-learn ni AIF360). Ce parcours suit la structure du cours IA708.


Table des matières

1	Vue d'ensemble du parcours	1
2	Les données : point de départ	2
3	Exploration : les biais préexistent dans les données	2
3.1	Extraction des attributs sensibles	2
3.2	Répartition des groupes	2
3.3	Ce que le notebook montre	3
4	Préparation des données	3
4.1	Retrait des attributs sensibles	3
4.2	Prétraitement : z-score et one-hot	3
4.3	Split stratifié 60/20/20	3
5	Modèle de base : régression logistique from scratch	4
5.1	Le modèle	4
5.2	Entraînement : Adam + régularisation	4
5.3	Seuil de décision	4
5.4	Ce que le notebook montre	4
6	Métriques : mesurer ce qui compte	5
6.1	Métriques de performance	5
6.2	Métriques d'équité (cf. cours fairness)	5
6.3	Évaluation du baseline	5
7	Reweighting : correction en pré-traitement	6
7.1	Principe	6

7.2	Calcul concret sur un mini-exemple	6
8	Seuils par groupe : correction en post-traitement	7
8.1	Principe	7
8.2	Illustration intuitive	7
9	Comparaison : 4 configurations	7
9.1	Tableau de résultats	7
9.2	Analyse détaillée	8
9.3	Le théorème d'impossibilité en action	8
9.4	Ce que le notebook montre	8
10	Interprétabilité : comprendre les décisions	9
10.1	SHAP linéaire exact	9
10.2	Importance par permutation	9
10.3	Détection de proxies	9
11	Robustesse : le modèle résiste-t-il au bruit ?	10
11.1	Protocole de perturbation	10
11.2	Résultats	10
11.3	Diagramme de calibration	10
12	Conclusion : ce qu'on a appris	11

1 Vue d'ensemble du parcours

Avant d'entrer dans le code, comprenons la **logique du parcours**. Chaque étape répond à une question qui motive naturellement la suivante :



Chaque flèche correspond à une **transition motivée** : on ne passe à l'étape suivante que parce que la précédente a soulevé une question. C'est cette logique narrative que nous allons dérouler.

2 Les données : point de départ

Étape 1 — Pourquoi ces données ?

Le **German Credit Dataset** (UCI Statlog, Hofmann 1994) est un cas d'école en IA responsable : 1 000 demandes de crédit décrites par 20 attributs. La cible est binaire : **défaul de paiement** (1) ou non (0). Le scoring crédit est une décision à fort impact humain — un refus injuste peut affecter la vie entière d'un demandeur.

Chargement. Le fichier `german.data` est un CSV séparé par espaces, sans entête. La cible originale est codée 1 (bon) / 2 (mauvais) ; on la transforme en `default` $\in \{0, 1\}$.

Caractéristique	Valeur	Proportion
Bon payeur (défaul = 0)	700	70 %
Mauvais payeur (défaul = 1)	300	30 %
Features numériques	7	—
Features catégorielles	13	—

TABLE 1 – Vue d'ensemble du dataset.

Premiers constats. Le déséquilibre 70/30 est important : un modèle qui prédirait toujours « bon » aurait 70 % d'accuracy. C'est pourquoi on utilisera des métriques adaptées (§6).

3 Exploration : les biais préexistent dans les données

Étape 2 — Y a-t-il déjà des biais ?

Avant même de construire un modèle, on examine si les données reflètent des disparités entre groupes. Si oui, tout modèle performant les **reproduira**.

3.1 Extraction des attributs sensibles

On définit deux attributs sensibles, conformément au cours *fairness* :

- **Genre** : extrait de la colonne `personal_status_sex`. Les codes A91, A93, A94 correspondent aux hommes ; A92, A95 aux femmes.
- **Âge** : binarisé au seuil de 25 ans. Adulte (> 25) vs jeune (≤ 25).

3.2 Répartition des groupes

Groupe	Effectif	Taux bon	Taux défaut
Homme	690 (69 %)	72 %	28 %
Femme	310 (31 %)	65 %	35 %
Adulte (> 25)	810 (81 %)	72 %	28 %
Jeune (≤ 25)	190 (19 %)	60 %	40 %

TABLE 2 – Taux de défaut par groupe — biais préexistants dans les données.

Leçon clé

Les femmes ont un taux de défaut plus élevé que les hommes (+7 points), et les jeunes plus que les adultes (+12 points). Ces écarts ne sont pas nécessairement « vrais » — ils peuvent refléter des biais historiques dans l'attribution des crédits. Un modèle entraîné sur ces données reproduira et potentiellement amplifiera ces disparités.

3.3 Ce que le notebook montre

Le notebook produit trois graphiques côte à côte :

1. **Distribution de la cible** — barre verte (bon) vs rouge (mauvais) : on voit le déséquilibre 70/30.
2. **Distribution par genre** — les hommes sont surreprésentés (69 %).
3. **Histogramme d'âge** avec le seuil 25 ans — la majorité sont des adultes, les jeunes sont une minorité (19 %).

Ces visualisations motivent la suite : comment construire un modèle qui soit performant *et* équitable ?

4 Préparation des données

Étape 3 — Comment préparer les données pour le modèle ?

Trois décisions clés : (1) retirer les attributs sensibles des features, (2) encoder les variables, (3) séparer train/validation/test.

4.1 Retrait des attributs sensibles

On retire `personal_status_sex` et `age_in_years` des features d'entraînement.

Attention : proxy

Retirer la colonne ne suffit pas toujours. D'autres features peuvent être **corrélées** à l'attribut sensible et servir de **proxy** — le modèle peut alors discriminer *indirectement*. On vérifiera cela à l'étape 9 (SHAP).

4.2 Prétraitement : z-score et one-hot

- **Numériques** (6 colonnes) : normalisation z-score $x' = \frac{x - \mu}{\sigma}$ avec μ et σ calculés sur le train uniquement (ddof = 1).
- **Catégorielles** (12 colonnes) : one-hot encoding. Chaque modalité devient une colonne binaire.

Résultat : ~44 features numériques après encodage.

Le préprocesseur est **fité sur le train** et **appliqué** au val/test — pas de fuite d'information.

```
prep = Preprocessor().fit(features.iloc[tr])
X_tr = prep.transform(features.iloc[tr]) # fit sur train
X_va = prep.transform(features.iloc[va]) # appliqué au val
X_te = prep.transform(features.iloc[te]) # appliqué au test
```

4.3 Split stratifié 60/20/20

La répartition est stratifiée par la cible : chaque sous-ensemble conserve le ratio 70/30. Le seed est fixé (`rng = default_rng(42)`) pour la reproductibilité.

	Train	Validation	Test
Taille	~600	~200	~200
Rôle	Entraînement	Choix du seuil, PP	Évaluation finale

5 Modèle de base : régression logistique from scratch

Étape 4 — Quel modèle, et comment l'entraîner ?

On implémente une régression logistique entièrement à la main. Pourquoi ? (1) C'est un modèle interprétable (chaque feature a un coefficient), (2) on maîtrise chaque étape, (3) le sujet l'exige.

5.1 Le modèle

La régression logistique modélise la probabilité de défaut :

$$P(\text{défaut} = 1 \mid x) = \sigma(w^\top x + b) \quad \text{avec} \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

où $w \in \mathbb{R}^d$ est le vecteur de poids et b le biais.

5.2 Entraînement : Adam + régularisation

La perte est la **cross-entropy binaire** :

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n s_i \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right] + \frac{\lambda}{2} \|w\|^2$$

où s_i est le poids de l'exemple (utilisé pour le reweighing, $s_i = 1$ pour le baseline) et $\lambda = 0.01$ est le coefficient L2.

Hyperparamètre	Valeur
Optimiseur	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$)
Learning rate	0.03
Régularisation	L2, $\lambda = 0.01$
Early stopping	Patience 300 (sur val loss)
Initialisation biais	$b_0 = \ln(\bar{y}/(1 - \bar{y}))$

TABLE 3 – Hyperparamètres de la régression logistique.

L'initialisation du biais à la log-odds de la moyenne cible permet une convergence plus rapide.

5.3 Seuil de décision

On ne fixe pas le seuil à 0.5. On balaye $\tau \in [0.1, 0.9]$ et on choisit celui qui maximise la **balanced accuracy** sur la validation :

$$\text{BalAcc} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right)$$

Ce choix est motivé par le déséquilibre 70/30 : un seuil fixe à 0.5 favorise la classe majoritaire.

5.4 Ce que le notebook montre

Le graphique de la **val loss** en fonction des epochs montre la convergence puis l'arrêt anticipé quand la perte ne diminue plus.

6 Métriques : mesurer ce qui compte

Étape 5 — Comment évaluer performance ET équité ?

La performance seule ne suffit pas. Il faut aussi mesurer si le modèle traite les groupes de manière équitable. On définit les deux familles de métriques utilisées dans tout le reste du parcours.

6.1 Métriques de performance

Métrique	Pourquoi ?
AUC ROC	Invariante au seuil. Mesure la capacité à séparer les classes. Ici calculée par la formule de Wilcoxon-Mann-Whitney.
Balanced Acc.	$\frac{1}{2}(\text{TPR} + \text{TNR})$. Adaptée au déséquilibre (vs accuracy naïve).
ECE	Expected Calibration Error. Vérifie que la confiance du modèle correspond à la réalité (cf. cours incertitude).

ECE — Expected Calibration Error. On découpe l'intervalle $[0, 1]$ en B bins par confiance, puis :

$$\text{ECE} = \sum_{b=1}^B \frac{|B_b|}{n} |\text{acc}(B_b) - \text{conf}(B_b)|$$

Un modèle bien calibré a $\text{ECE} \approx 0$. La régression logistique est naturellement bien calibrée.

6.2 Métriques d'équité (cf. cours fairness)

Soit S l'attribut sensible, Y la cible, $\hat{Y}$ la prédiction.

Critère	Définition	Signification
Demographic Parity	$ P(\hat{Y}=1 \mid S=0) - P(\hat{Y}=1 \mid S=1) $	Même taux de sélection
Equal Opportunity	$ \text{TPR}_{S=0} - \text{TPR}_{S=1} $	Même rappel sur les vrais positifs

Un modèle parfaitement équitable aurait $|\Delta\text{DP}| = 0$ et $|\Delta\text{EO}| = 0$. En pratique, c'est impossible simultanément (§9.3).

6.3 Évaluation du baseline

Le notebook affiche les résultats du baseline :

Attribut	Groupe	Taux sélection	TPR	Effectif test
Genre	Homme	≈ 0.41	≈ 0.70	~ 140
	Femme	≈ 0.50	≈ 0.74	~ 60
Âge	Adulte	≈ 0.42	≈ 0.77	~ 160
	Jeune	≈ 0.51	≈ 0.59	~ 40

TABLE 4 – Métriques d'équité du baseline (valeurs approchées, dépendent du seed).

Constat

Le baseline n'est pas équitable. Pour l'âge, le $|\Delta EO| \approx 0.18$: les jeunes défaillants sont beaucoup moins bien détectés que les adultes. C'est **préoccupant** — cela justifie l'étape suivante.

7 Reweighing : correction en pré-traitement

Étape 6 — Peut-on corriger les biais sans changer le modèle ?

Le **reweighing** (cf. cours fairness-mitigation) est une méthode de pré-traitement : on repondère les exemples d'entraînement pour équilibrer la relation entre S et Y .

7.1 Principe

L'idée est simple : si un sous-groupe est sous-représenté dans une classe, on augmente son poids. Formellement :

$$w_i = \frac{P(S = s_i) \cdot P(Y = y_i)}{P(S = s_i, Y = y_i)}$$

Ce poids rend $S \perp Y$ dans la distribution pondérée.

7.2 Calcul concret sur un mini-exemple

Imaginons un mini-TRAIN de 100 personnes, avec les comptages croisés suivants :

	$Y = 0$ (bon)	$Y = 1$ (défaut)	Total S
$S = \text{Homme}$	50	20	70
$S = \text{Femme}$	20	10	30
Total Y	70	30	100

TABLE 5 – Mini-exemple : effectifs croisés.

Calcul des probabilités : $P(S=H) = 0,7$, $P(S=F) = 0,3$, $P(Y=0) = 0,7$, $P(Y=1) = 0,3$.

Calcul des poids pour chaque cellule :

- $(H, Y=0)$: $w = \frac{0,7 \times 0,7}{0,50} = 0,98$ (légèrement diminué, surreprésenté)
- $(H, Y=1)$: $w = \frac{0,7 \times 0,3}{0,20} = 1,05$ (légèrement augmenté)
- $(F, Y=0)$: $w = \frac{0,3 \times 0,7}{0,20} = 1,05$ (femmes « bonnes » : sous-repr.)
- $(F, Y=1)$: $w = \frac{0,3 \times 0,3}{0,10} = 0,90$ (femmes en défaut : surrepr.)

Après pondération, $S \perp Y$: la corrélation entre genre et défaut disparaît dans la perte d'entraînement.

Direction générale

Privilégié “mauvais” et non-privilégié “bon” reçoivent $w > 1$. Privilégié “bon” et non-privilégié “mauvais” reçoivent $w < 1$. C'est exactement ce qu'il faut pour casser la corrélation S – Y .

On entraîne ensuite un **nouveau modèle** avec ces poids (paramètre `sample_weight` dans `train_logreg`). Un modèle repondéré est entraîné **par attribut sensible**.

8 Seuils par groupe : correction en post-traitement

Étape 7 — Peut-on corriger sans ré-entraîner ?


Le post-traitement ajuste le seuil de classification **séparément par groupe** pour égaliser le taux de sélection (Demographic Parity).

8.1 Principe

Au lieu d'un seuil global τ , on calibre τ_{g_0} et τ_{g_1} sur la validation pour que :

$$P(\hat{Y}=1 \mid S=g_0) \approx P(\hat{Y}=1 \mid S=g_1)$$

8.2 Illustration intuitive



Les deux groupes ont des distributions de scores différentes. En appliquant le même seuil, on sélectionnerait des proportions différentes. La calibration par groupe rééquilibre cela.

Avantage

Pas de ré-entraînement. On utilise le même modèle, seul le seuil change. Très rapide.

Limite

Calibré sur ~ 200 exemples : seuils potentiellement instables. Et juridiquement, des seuils différents par groupe peuvent être problématiques.

9 Comparaison : 4 configurations

Étape 8 — Quel est l'effet réel des corrections ?

On compare systématiquement 4 configurations pour chaque attribut sensible : (1) Baseline, (2) Reweighing, (3) Baseline + post-processing, (4) Reweighing + post-processing.

9.1 Tableau de résultats

Attr.	Configuration	AUC	BalAcc	$ \Delta DP $	$ \Delta EO $
Genre	Baseline	0.793	0.701	0.094	0.044
Genre	Reweighing	0.793	0.701	0.094	0.044
Genre	Reweighing + PP	0.793	0.727	0.238	0.192
Âge	Baseline	0.793	0.701	0.081	0.179
Âge	Reweighing	0.789	0.713	0.081	0.202
Âge	Reweighing + PP	0.789	0.712	0.056	0.261

TABLE 6 – Performance et équité sur le test (PP = post-processing par seuils/groupe).

9.2 Analyse détaillée

Genre — le reweighing n'a aucun effet. Les lignes Baseline et Reweighing sont **identiques** ($AUC = 0.793$, $|\Delta DP| = 0.094$). Cela signifie que repondérer les exemples n'a pas modifié le modèle. Pourquoi? Parce qu'après retrait de `personal_status_sex`, les features restantes ne sont que faiblement corrélées au genre. Il n'y a pas de **proxy fort** — le modèle ne « voit » pas le genre. Nous confirmerons cela à l'étape 9 (SHAP).


Âge — le reweighing modifie le modèle. L'AUC passe de 0.793 à 0.789 : le reweighing a réellement changé les poids du modèle. C'est parce que des features comme `duration_in_month` sont corrélées à l'âge — ce sont des **proxies actifs**. Le reweighing + PP réduit $|\Delta DP|$ de 0.081 à **0.056** (amélioration), **mais** $|\Delta EO|$ augmente de 0.179 à 0.261.

9.3 Le théorème d'impossibilité en action

Théorème d'impossibilité (Chouldechova 2017, Kleinberg 2016)

Il est **mathématiquement impossible** de satisfaire simultanément Demographic Parity, Equal Opportunity et calibration, sauf si les taux de base sont égaux entre groupes — ce qui n'est pas le cas ici.

Visualisation géométrique du compromis.



Les configurations du modèle se déplacent sur une **frontière de Pareto** : on ne peut améliorer une dimension qu'au prix d'une autre. Le point idéal (0,0) est inaccessible.

À retenir

Nos résultats sur l'âge illustrent ce théorème : réduire $|\Delta DP|$ **augmente** $|\Delta EO|$. Ce n'est pas un échec — c'est une **limite fondamentale**. En pratique, il faut choisir le critère selon le contexte métier (« recall » pour la médecine, « selection rate » pour le recrutement, etc.).

9.4 Ce que le notebook montre

Le graphique en **scatter plot** (AUC vs $|\Delta DP|$) visualise ce compromis : les points se déplacent vers la gauche (plus équitable) au prix d'un léger recul en performance ou d'une hausse de $|\Delta EO|$.

10 Interprétabilité : comprendre les décisions

Étape 9 — Pourquoi le modèle prend-il ces décisions ?

L'interprétabilité est essentielle pour (1) expliquer les décisions aux utilisateurs, (2) détecter la discrimination indirecte via les proxies. Deux méthodes complémentaires sont utilisées.

10.1 SHAP linéaire exact

Pour un modèle linéaire, les **valeurs de Shapley** (cf. cours interprétabilité) ont une forme fermée exacte :

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}_{\text{train}}[x_i])$$

où w_i est le coefficient du modèle et $\mathbb{E}_{\text{train}}[x_i]$ la moyenne de la feature i sur le train. La contribution est signée : positive si la feature pousse vers le défaut, négative sinon. Pour les features catégorielles (one-hot), on somme les contributions des dummies associées.

Top features (baseline). Les features les plus influentes sont typiquement :

1. `checking_status` — le statut du compte courant
2. `duration_in_month` — la durée du crédit
3. `credit_amount` — le montant
4. `credit_history` — l'historique
5. `savings_account_bonds` — l'épargne

10.2 Importance par permutation

Méthode complémentaire : on mélange aléatoirement une colonne et on mesure la **chute d'AUC**. Si l'AUC diminue beaucoup, la feature est importante. On répète 10 fois par feature pour stabiliser.

Convergence des deux méthodes

SHAP (local $\rightarrow$ global) et permutation (global) convergent sur le classement des features. C'est rassurant : les deux approches donnent la même image des décisions du modèle.

10.3 Détection de proxies

Un **proxy** est une feature qui est à la fois :

1. **Corrélée** à l'attribut sensible ($|r| > 0.15$), et
2. **Influente** dans le modèle (SHAP élevé).

Attribut	Proxies ?	Conséquence
Genre	Aucun proxy fort	Retirer la colonne suffit $\Rightarrow$ reweighing sans effet
Âge	<code>duration_in_month</code> ($ r > 0.15$, top 2 SHAP)	Le modèle « voit » l'âge $\Rightarrow$ reweighing a un effet

TABLE 7 – Résumé de la détection de proxies.

Leçon fondamentale

La détection de proxies **explique** pourquoi le reweighing fonctionne pour l'âge mais pas pour le genre. L'interprétabilité n'est pas un bonus — c'est un outil essentiel pour comprendre et diagnostiquer les problèmes d'équité.

11 Robustesse : le modèle résiste-t-il au bruit ?

Étape 10 — Les corrections d'équité fragilisent-elles le modèle ?

Un modèle déployé recevra des données bruitées (erreurs de saisie, mesures imprécises). On simule ce bruit et on vérifie la stabilité des prédictions.

11.1 Protocole de perturbation

- **Features numériques** : $x_j \leftarrow x_j + \varepsilon$, avec $\varepsilon \sim \mathcal{N}(0, 0.2 \cdot \sigma_j^{\text{train}})$.
- **Features catégorielles** : remplacement aléatoire par une autre modalité avec probabilité $p = 0.1$.

Ce niveau de bruit simule des erreurs réalistes (20 % de l'écart-type pour les numériques, 10 % de swaps pour les catégoriels).

11.2 Résultats

	AUC	Balanced Acc.	ECE
Clean	0.7932	0.7012	0.0575
Perturbé	0.7877	0.7048	0.0482
Δ	-0.0055	+0.0036	-0.0092

TABLE 8 – Dégradation sous perturbation (seed 43).

- **Corrélation des scores** : $r \approx 0.97$ entre scores clean et perturbés.
- **Dégradation AUC** : moins d'1 point — très modérée.
- **ECE** : légèrement réduit (la perturbation a un effet de régularisation).
- Les modèles fair sont **aussi robustes** que le baseline.

11.3 Diagramme de calibration

Le notebook affiche les **reliability diagrams** côte à côte (clean vs perturbé). Chaque barre représente un bin de confiance : si le modèle est bien calibré, les barres suivent la diagonale.

Leçon


Les corrections d'équité (reweighing, seuils par groupe) **n'amplifient pas la fragilité**. Le modèle linéaire est naturellement robuste aux petites perturbations, et cette propriété est préservée.

12 Conclusion : ce qu'on a appris

Étape 11 — Quelles leçons tirer ?


Le parcours complet nous enseigne six leçons fondamentales, qui relient les trois piliers du cours (équité, interprétabilité, robustesse).

1. **Les données sont biaisées.** Les taux de défaut diffèrent entre groupes (Table 2). Un modèle performant reproduira ces biais — bonne performance $\neq$ modèle équitable.
2. **Retirer l'attribut sensible ne suffit pas toujours.** Pour le genre, oui (pas de proxy fort). Pour l'âge, non : `duration_in_month` encode l'âge indirectement (proxy actif).
3. **Le reweighing est efficace quand il y a des proxies.** Sans proxy, il ne change rien (genre). Avec proxy, il modifie réellement le modèle (âge).
4. **Le compromis DP/EO est inévitable.** Réduire $|\Delta DP|$ augmente $|\Delta EO|$ (Table 6). C'est le théorème d'impossibilité — pas un échec de la méthode.
5. **L'interprétabilité éclaire l'équité.** SHAP + corrélation = détection de proxies. Sans cette analyse, on ne comprendrait pas pourquoi le reweighing fonctionne pour un attribut et pas l'autre.
6. **Le modèle est robuste**, même après corrections. Corrélation $r \approx 0.97$, dégradation modérée, ECE stable.



Les trois piliers sont interdépendants : l'interprétabilité révèle les problèmes d'équité, la robustesse garantit que les corrections sont fiables.

Arbre de décision : que faire selon la situation ?



Code from scratch — numpy et pandas uniquement.