

IA Responsable, German Credit Dataset


Parcours pédagogique du notebook `responsiveAI-german-credit.ipynb`

IA708 – Télécom Paris

2026


- 1 Vue d'ensemble du parcours
- 2 Données et baseline
- 3 Métriques d'équité
- 4 Mitigation de l'inéquité
- 5 Interprétabilité
- 6 Quantification d'incertitude
- 7 Calibration et conclusion

Le parcours en 12 étapes



Trois axes du sujet : équité (vert), interprétabilité (jaune via SHAP), incertitude (orange, substitut au volet robustesse).

1-2. UCI German Credit, exploration



Le dataset

1000 demandes de crédit, 20 attributs (6 num + 14 cat).

Cible : **défaut de paiement** (30%) vs bon payeur (70%).

Attributs sensibles

- **Genre** : extrait de `personal_status_sex` (690 hommes / 310 femmes)
- **Âge** : binarisé au seuil **25 ans** (810 older / 190 younger)

Biais brut visible

Taux de défaut : **younger 42%** vs older 27%,
female 35% vs male 28%


Pipeline scikit-learn

- **ColumnTransformer** :
 - StandardScaler (num)
 - OneHotEncoder (cat)
- Split stratifié **60/20/20**
- **Retrait** de `personal_status_sex` et `age_in_years` pour éviter la discrimination directe

Baseline

LogisticRegression L2, $C = 1$, liblinear.

Convergence : log-loss train 0.43 dès 10 iter, val 0.56 (cible ≈ 0.5).



Convergence quasi-instantanée (liblinear).

5. Trois familles de métriques d'équité

Demographic Parity

$$\hat{Y} \perp A$$

$$|\Pr(\hat{Y} = 1|A = 0) - \Pr(\hat{Y} = 1|A = 1)|$$

même taux de sélection

Equal Opportunity

$$\hat{Y} \perp A \mid Y = 1$$

$$|\text{TPR}_{A=0} - \text{TPR}_{A=1}|$$

même taux de vrais positifs

Calibration

$$\Pr(Y = 1 \mid S = s) \approx s$$

$$\text{ECE} = \sum_b \frac{|B_b|}{n} |\text{acc} - \text{conf}|$$


score = vraie probabilité

Théorème d'impossibilité (Chouldechova 2017, Kleinberg 2016)

Si les taux de base diffèrent entre groupes ($p_0 \neq p_1$) : **on ne peut pas** satisfaire deux de ces critères simultanément.

$$\frac{\text{PPV}}{1 - \text{PPV}} = \frac{p}{1 - p} \cdot \frac{1 - \text{FNR}}{\text{FPR}}$$





6-7. Trois familles de mitigation (cours)



$$\text{Reweighing : poids } w_i = \frac{P(S = s_i) P(Y = y_i)}{P(S = s_i, Y = y_i)}$$

Rend $S \perp Y$ dans la distribution pondérée. Si les femmes sans défaut sont sous-représentées, on augmente leur poids.


8. Compromis performance / équité (4 configs)



9. SHAP linéaire : formule exacte

Pour un modèle linéaire (Lundberg & Lee 2017, Corollary 1)

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}[x_i])$$




Lecture

Top features SHAP :

- checking_status (loin devant)
- credit_history
- installment_rate
- savings_account_bonds
- purpose, credit_amount

⇒ Le modèle s'appuie sur des variables **financières légitimes**, pas (en apparence) sur des proxies sensibles.

9. SHAP vs Permutation Importance



Les deux méthodes s'accordent : `checking_status`, `credit_history`, `credit_amount`, `duration_in_month` dominant. Concordance $\Rightarrow$ confiance accrue dans le diagnostic.

Régression logistique features → attribut sensible

Si on peut prédire A depuis les features, alors A est encodé indirectement.

Attribut	AUC proxy	Lecture
Genre	0.69	signal proxy modéré
Âge	0.86	très fortement reconstituable

Conséquence méthodologique





Retirer `age_in_years` ne suffit pas à "cacher" l'âge : il est encodé dans `housing`, `employment`, `job`...

Recommandation Charlotte : *ne pas retirer les attributs sensibles*, mais les utiliser comme pondérations dans une mitigation explicite (*fairness through awareness*).

10. Bootstrap : substitut à la robustesse adversariale

Choix méthodologique (feedback Charlotte)

Robustesse adversariale (perturbation gaussienne) → **Bootstrap CI** (incertitude épistémique). Inspiré du cours *Robustness and Uncertainty* (G. Franchi).





10. Intervalles de confiance bootstrap (B=200)

Métrique	Moyenne	σ	IC 2.5%	IC 97.5%
AUC	0.764	0.019	0.723	0.795
BalAcc	0.682	0.023	0.637	0.726
$ \Delta DP $ genre	0.035	0.028	0.001	0.105
$ \Delta EO $ genre	0.089	0.044	0.017	0.176
$ \Delta DP $ âge	0.104	0.046	0.020	0.202
$ \Delta EO $ âge	0.086	0.048	0.018	0.194

Lecture critique

Le biais $|\Delta DP|$ âge = 0.125 a un IC95% [**0.02**, **0.20**]. Très large : sur 1000 lignes, les conclusions doivent être nuancées par l'incertitude statistique.



10. Incertitude par individu



À gauche : IC 95% par individu, trié par score. Les individus près du seuil sont les plus incertains.

À droite : la fameuse parabole, σ max au milieu (proba ≈ 0.5). C'est l'incertitude *épistémique*.

11. Calibration : ECE et Platt scaling



ECE

$$ECE = \sum_b \frac{|B_b|}{n} |\text{acc}(B_b) - \text{conf}(B_b)|$$

Modèle	ECE
Baseline	0.082
Platt scaling	0.080

Gain marginal : la régression logistique est naturellement bien calibrée.

12. Conclusion

Équité

Biais d'âge significatif (0.125),
genre négligeable. PP réduit DP
mais double EO (impossibilité).

Interprétabilité

SHAP + perm convergent.
Proxy AUC = 0.86 pour
l'âge $\Rightarrow$ retrait insuffisant.

Incertitude

IC95% large sur DP $\Rightarrow$ prudence
statistique. Calibration déjà bonne.

Limites & pistes

Petit dataset, linéaire, re-
weighing simple. Pistes :
ExponentiatedGradient, trans-
port optimal, fairness through
awareness avec age conservé.

- Lundberg & Lee, *A Unified Approach to Interpreting Model Predictions*, NeurIPS 2017
- Chouldechova, *Fair prediction with disparate impact*, Big Data 2017
- Kleinberg, Mullainathan, Raghavan, *Inherent trade-offs in the fair determination of risk scores*, ITCS 2017
- Kamiran & Calders, *Data preprocessing techniques for classification without discrimination*, KAIS 2012 (reweighing)
- Cours IA708 : F. d'Alché-Buc, C. Laclau, G. Franchi

Code : `responsiveAI-german-credit.ipynb` (sklearn + fairlearn + shap)

Outputs : `outputs/*.png` **Reproductibilité** : `papermill`