

IA Responsable : German Credit Dataset

Équité, Interprétabilité & Quantification d'incertitude

IA708 – Télécom Paris

2026

Plan

- 1 Les données
- 2 Modélisation
- 3 Équité
- 4 Interprétabilité
- 5 Quantification d'incertitude
- 6 Synthèse

UCI Statlog (Hofmann, 1994)

- 1 000 demandes de crédit
- 20 attributs (7 num., 13 cat.)
- Cible : défaut de paiement

Pourquoi ce dataset ?

- Scoring crédit = décision à fort impact humain
- Risque de discrimination historique
- Cas d'école en IA responsable

Stat	Valeur
Bon payeur (0)	700 (70%)
Mauvais (1)	300 (30%)
Hommes	690 (69%)
Femmes	310 (31%)
Adultes (>25)	810 (81%)
Jeunes (≤ 25)	190 (19%)

Déséquilibre de la cible ET des groupes

Exploration : biais dans les données

Constat clé : les taux de défaut diffèrent **déjà** entre groupes.

Genre	Bon	Défaut
Homme	72%	28%
Femme	65%	35%

Écart ≈ 7 points

Âge	Bon	Défaut
Adulte	72%	28%
Jeune	60%	40%

Écart ≈ 12 points

Conséquence

Un modèle qui prédit bien reproduira ces disparités historiques. $\Rightarrow$ **bonne performance $\neq$ modèle équitable.**

Choix : deux attributs sensibles

Genre

- Extrait de `personal_status_sex`
- Privilégié : homme
- Biais modéré dans les données

Âge


- Binarisé au seuil de 25 ans
- Privilégié : adulte
- Biais plus marqué (12 points)

Décision de conception

Les deux colonnes (`personal_status_sex`, `age_in_years`) sont **retirées des features** $\Rightarrow$ pas de discrimination *directe*.

Mais des **proxies** (variables corrélées) peuvent encoder indirectement l'information sensible. On le vérifiera via SHAP.

Pipeline complet



Stack : scikit-learn + fairlearn + shap, reproductibilité via papermill.

Régression logistique : $P(\text{défaut} = 1 \mid x) = \sigma(w^\top x + b)$

Entraînement

- `sklearn.LogisticRegression`, solver `liblinear`, `C=1`
- L2 régularisée, `max_iter = 1000`
- Convergence vérifiée : log-loss val 0.56 dès 10 itérations (seuil ~ 0.5 attendu)
- Seuil : max balanced accuracy (val) $\rightarrow \tau = 0.18$

Prétraitement (ColumnTransformer)

- `StandardScaler` (num.) + `OneHotEncoder` (cat.)
- 56 features après encodage
- Genre et âge retirés (choix initial)

Choix des métriques

Dataset déséquilibré (70/30) $\Rightarrow$ accuracy simple trompeuse.

On utilise **AUC ROC** (invariant au seuil), **balanced accuracy** $= \frac{1}{2}(\text{TPR} + \text{TNR})$, et **ECE** (calibration).

Résultats baseline : équité

Question : le baseline est-il équitable ?

Genre		
	Sélection	TPR
Homme	0.633	0.85
Femme	0.623	0.90
$ \Delta $	0.010	0.058

Âge		
	Sélection	TPR
Older	0.603	0.85
Younger	0.727	0.90
$ \Delta $	0.125	0.066

Analyse : sur le **genre**, biais quasi-nul une fois `personal_status_sex` retiré ; sur l'**âge**, $|\Delta DP| = 0.125$ persiste car les taux de défaut diffèrent (younger 42 % vs older 27 %). $\Rightarrow$ **correction nécessaire pour l'âge**.

Définitions (cours fairness)

Soit S l'attribut sensible, Y la cible, $\hat{Y}$ la prédiction.

Critère	Signification	On mesure
Demographic Parity	Même taux de sélection	$ P(\hat{Y}=1 S=0) - P(\hat{Y}=1 S=1) $
Equal Opportunity	Même TPR	$ \text{TPR}_{S=0} - \text{TPR}_{S=1} $
Equalized Odds	Même TPR + FPR	EOpp + même FPR

Théorème d'impossibilité (Chouldechova 2017, Kleinberg 2016)

On **ne peut pas** satisfaire DP, EO et calibration simultanément (sauf si les taux de base sont égaux entre groupes). $\Rightarrow$ Il faut **choisir** ses compromis.

Reweighting (pré-traitement)

Idée : repondérer les exemples pour rendre $S \perp Y$ dans le train.

$$w_i = \frac{P(S=s_i) \cdot P(Y=y_i)}{P(S=s_i, Y=y_i)}$$

Si les femmes sans défaut sont sous-représentées $\Rightarrow$
on augmente leur poids.

Un modèle par attribut sensible.

Groupe	$Y=0$	$Y=1$
Privil.	$w \approx 1$	$w > 1$
Non-priv.	$w > 1$	$w \approx 1$

Seuils par groupe (post-traitement)

Idée : ajuster le seuil de classification par groupe sur la validation.

- Seuil global $\tau \rightarrow$ seuils τ_{g0}, τ_{g1}
- Critère : égaliser le taux de sélection (DP)
- Calibré sur la validation (~ 200 exemples)

Avantage

Pas de ré-entraînement.

Limite

Peu de données de calibration $\Rightarrow$ bruit.

Résultats : comparaison des 4 configurations

Attr.	Config.	AUC	BalAcc	$ \Delta DP $	$ \Delta EO $
Genre	Baseline	0.785	0.669	0.010	0.058
Genre	Reweighing	0.785	0.665	0.006	0.050
Genre	Baseline + PP	0.785	0.669	0.105	0.196
Genre	Reweighing + PP	0.785	0.669	0.128	0.230
Âge	Baseline	0.785	0.669	0.125	0.066
Âge	Reweighing	0.784	0.640	0.132	0.098
Âge	Baseline + PP	0.785	0.644	0.060	0.135
Âge	Reweighing + PP	0.784	0.650	0.069	0.221

Analyse :

- **Genre** : biais initial négligeable, le PP **crée** un biais artificiel (val=200 trop petit)
- **Âge** : PP réduit $|\Delta DP|$ (0.125 $\rightarrow$ **0.060**) mais **double** $|\Delta EO|$ (0.066 $\rightarrow$ 0.135) $\Rightarrow$ **théorème d'impossibilité en action**

SHAP linéaire exact

Question : quelles features déterminent les décisions ?

Pour un modèle linéaire, les **valeurs de Shapley** sont exactes :

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}_{\text{train}}[x_i])$$

Top 5 features (SHAP baseline, via `shap.LinearExplainer`) :

- ① `checking_status` — compte courant
- ② `credit_history` — historique
- ③ `installment_rate` — taux d'échéance
- ④ `savings_account_bonds` — épargne
- ⑤ `purpose, credit_amount, duration_in_month`

Complété par l'**importance par permutation**

(`sklearn.inspection.permutation_importance`, chute d'AUC quand on mélange une colonne). Les deux méthodes convergent sur le top.

Détection de proxies (approche Charlotte)

Question : peut-on prédire l'attribut sensible à partir des autres features ?

Méthode : régression logistique features $\rightarrow$ attribut sensible, AUC mesure le signal proxy multivarié.

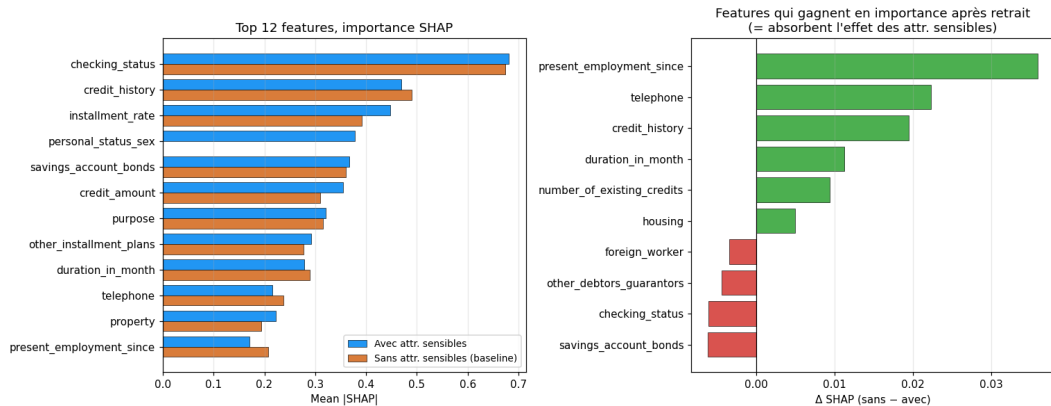
Attribut	AUC proxy	Interprétation
Genre	0.69	signal proxy modéré
Âge	0.86	très fortement reconstructible

Leçon

Retirer `age_in_years` ne suffit pas à « cacher » l'âge : il est encodé dans `housing`, `employment`, `job`...

Recommandation Charlotte : ne pas retirer les attributs sensibles, les utiliser explicitement comme pondérations (*fairness through awareness*).

SHAP : avant vs après retrait des attributs sensibles



Coût performance : AUC avec = 0.781, AUC sans = 0.785, retrait quasi gratuit. **Top absorbantes :** present_employment_since (+0.036), telephone (+0.022), credit_history (+0.020).

Leçon : l'effet se redistribue aux proxies. SHAP rend visible ce que l'AUC proxy = 0.86 mesure numériquement.

Bootstrap (substitut à la robustesse adversariale)

Choix méthodologique (feedback Charlotte) : la robustesse adversariale est remplacée par une **quantification d'incertitude par bootstrap** (cf. cours *Robustness and Uncertainty*).

Protocole

- $B = 200$ modèles entraînés sur des échantillons tirés avec remplacement
- Quantiles 2.5 % / 97.5 % des B valeurs $\rightarrow$ IC95 %
- Sur AUC, $|\Delta P|$, $|\Delta EO|$, et scores individuels

Résultats

- AUC : 0.764 [0.72, 0.80]
- $|\Delta DP|$ âge : 0.10 [0.02, 0.20]
- $|\Delta EO|$ âge : 0.09 [0.02, 0.19]

Lecture critique

Sur 1000 lignes, les IC sur les biais dépassent 0.15 $\Rightarrow$ **prudence statistique**, les conclusions de discrimination doivent être nuancées.

ECE (cours *Robustness and Uncertainty*) :
$$\text{ECE} = \sum_b \frac{|B_b|}{n} |\text{acc}_b - \text{conf}_b|$$

Modèle	ECE
Baseline (Rég. logist.)	0.082
Platt scaling (CalibratedClassifierCV)	0.080

⇒ La régression logistique est **naturellement bien calibrée**, le gain marginal du Platt scaling est minime.

Ce qu'on a appris

- ❶ **Les données sont biaisées sur l'âge** (younger 42 % vs older 27 % de défaut), pas sur le genre après retrait de `personal_status_sex`.
- ❷ **Retirer l'attribut sensible ne suffit pas** : la régression logistique features $\rightarrow$ âge a un **AUC = 0.86**. L'âge est largement encodé dans les autres variables (`housing`, `employment...`).
- ❸ **Compromis DP/EO inévitable** : sur l'âge, le post-processing réduit $|\Delta DP|$ ($0.125 \rightarrow 0.060$) mais **double** $|\Delta EO|$ ($0.066 \rightarrow 0.135$). Théorème d'impossibilité.
- ❹ **L'interprétabilité éclaire l'équité** : SHAP + permutation + régression sur l'attribut sensible = détection multi-niveaux des proxies.
- ❺ **Bootstrap = robustesse statistique** : IC95 % large sur les biais (0.02 à 0.20 pour $|\Delta DP|$ âge) $\Rightarrow$ prudence méthodologique.
- ❻ **Recommandation Charlotte** : pour aller plus loin, conserver l'attribut sensible et appliquer une mitigation explicite (*fairness through awareness*, `ExponentiatedGradient`, `transport optimal`).

Stack : scikit-learn + fairlearn + shap, reproductibilité via papermill.