

IA Responsable : German Credit Dataset

Équité, Interprétabilité & Robustesse

IA708 – Télécom Paris

2026

Plan

- 1 Les données
- 2 Modélisation
- 3 Équité
- 4 Interprétabilité
- 5 Robustesse
- 6 Synthèse

UCI Statlog (Hofmann, 1994)

- 1 000 demandes de crédit
- 20 attributs (7 num., 13 cat.)
- Cible : défaut de paiement

Pourquoi ce dataset ?

- Scoring crédit = décision à fort impact humain
- Risque de discrimination historique
- Cas d'école en IA responsable

Stat	Valeur
Bon payeur (0)	700 (70%)
Mauvais (1)	300 (30%)
Hommes	690 (69%)
Femmes	310 (31%)
Adultes (>25)	810 (81%)
Jeunes (≤ 25)	190 (19%)

Déséquilibre de la cible ET des groupes

Exploration : biais dans les données

Constat clé : les taux de défaut diffèrent **déjà** entre groupes.

Genre	Bon	Défaut
Homme	72%	28%
Femme	65%	35%

Écart ≈ 7 points

Âge	Bon	Défaut
Adulte	72%	28%
Jeune	60%	40%

Écart ≈ 12 points

Conséquence

Un modèle qui prédit bien reproduira ces disparités historiques. $\Rightarrow$ **bonne performance $\neq$ modèle équitable.**

Choix : deux attributs sensibles

Genre

- Extrait de `personal_status_sex`
- Privilégié : homme
- Biais modéré dans les données

Âge


- Binarisé au seuil de 25 ans
- Privilégié : adulte
- Biais plus marqué (12 points)

Décision de conception

Les deux colonnes (`personal_status_sex`, `age_in_years`) sont **retirées des features** $\Rightarrow$ pas de discrimination *directe*.

Mais des **proxies** (variables corrélées) peuvent encoder indirectement l'information sensible. On le vérifiera via SHAP.

Pipeline complet



Tout codé *from scratch* (numpy/pandas, sans scikit-learn).

Régression logistique : $P(\text{défaut} = 1 \mid x) = \sigma(w^\top x + b)$

Entraînement

- Adam ($\text{lr} = 0.03$), L2 ($\lambda = 0.01$)
- Early stopping (patience 300)
- Seuil : max balanced accuracy (val)

Prétraitement

- z-score (num.) + one-hot (cat.)
- ~ 44 features après encodage
- Genre et âge retirés

Choix des métriques

Dataset déséquilibré (70/30) $\Rightarrow$ accuracy simple trompeuse.

On utilise **AUC ROC** (invariant au seuil), **balanced accuracy** $= \frac{1}{2}(\text{TPR} + \text{TNR})$, et **ECE** (calibration).

Résultats baseline : équité

Question : le baseline est-il équitable ?

Genre		
	Sélection	TPR
Homme	0.406	0.697
Femme	0.500	0.741
$ \Delta $	0.094	0.044

Âge		
	Sélection	TPR
Adulte	0.425	0.767
Jeune	0.506	0.588
$ \Delta $	0.081	0.179

Analyse : le baseline présente des écarts mesurables. Le $|\text{EO gap}|$ pour l'âge (0.179) est préoccupant : les jeunes défaillants sont moins bien détectés. $\Rightarrow$ **correction nécessaire.**

Définitions (cours fairness)

Soit S l'attribut sensible, Y la cible, $\hat{Y}$ la prédiction.

Critère	Signification	On mesure
Demographic Parity	Même taux de sélection	$ P(\hat{Y}=1 S=0) - P(\hat{Y}=1 S=1) $
Equal Opportunity	Même TPR	$ \text{TPR}_{S=0} - \text{TPR}_{S=1} $
Equalized Odds	Même TPR + FPR	EOpp + même FPR

Théorème d'impossibilité (Chouldechova 2017, Kleinberg 2016)

On **ne peut pas** satisfaire DP, EO et calibration simultanément (sauf si les taux de base sont égaux entre groupes). $\Rightarrow$ Il faut **choisir** ses compromis.

Reweighting (pré-traitement)

Idée : repondérer les exemples pour rendre $S \perp Y$ dans le train.

$$w_i = \frac{P(S=s_i) \cdot P(Y=y_i)}{P(S=s_i, Y=y_i)}$$

Si les femmes sans défaut sont sous-représentées $\Rightarrow$
on augmente leur poids.

Un modèle par attribut sensible.

Groupe	$Y=0$	$Y=1$
Privil.	$w \approx 1$	$w > 1$
Non-priv.	$w > 1$	$w \approx 1$

Seuils par groupe (post-traitement)

Idée : ajuster le seuil de classification par groupe sur la validation.

- Seuil global $\tau \rightarrow$ seuils τ_{g0}, τ_{g1}
- Critère : égaliser le taux de sélection (DP)
- Calibré sur la validation (~ 200 exemples)

Avantage

Pas de ré-entraînement.

Limite

Peu de données de calibration $\Rightarrow$ bruit.

Résultats : comparaison des 4 configurations

Attr.	Config.	AUC	BalAcc	$ \Delta DP $	$ \Delta EO $
Genre	Baseline	0.793	0.701	0.094	0.044
Genre	Reweighting	0.793	0.701	0.094	0.044
Genre	Reweighting + PP	0.793	0.727	0.238	0.192
Âge	Baseline	0.793	0.701	0.081	0.179
Âge	Reweighting	0.789	0.713	0.081	0.202
Âge	Reweighting + PP	0.789	0.712	0.056	0.261

Analyse :

- **Genre** : reweighting **sans effet** $\Rightarrow$ proxies faibles
- **Âge** : reweighting + PP réduit $|\Delta DP|$ ($0.081 \rightarrow \mathbf{0.056}$)
- Mais $|\Delta EO|$ augmente ($0.179 \rightarrow 0.261$) $\Rightarrow$ **théorème d'impossibilité en action**

SHAP linéaire exact

Question : quelles features déterminent les décisions ?

Pour un modèle linéaire, les **valeurs de Shapley** sont exactes :

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}_{\text{train}}[x_i])$$

Top 5 features (SHAP baseline) :

- 1 checking_status — compte courant
- 2 duration_in_month — durée du crédit
- 3 credit_amount — montant
- 4 credit_history — historique
- 5 savings_account_bonds — épargne

Complété par l'**importance par permutation** (chute d'AUC quand on mélange une colonne).
Les deux méthodes convergent.

Détection de proxies

Question : des features encodent-elles indirectement le genre ou l'âge ?

Genre

- Aucune feature à la fois influente ET corrélée au genre
- **Proxies faibles**
- $\Rightarrow$ Retirer l'attribut suffit
- Cohérent avec le reweighing sans effet

Âge

- `duration_in_month` : corrélé à l'âge ($|r| > 0.15$) ET important (top 2 SHAP)
- **Proxy actif**
- $\Rightarrow$ Le modèle "voit" l'âge même sans la colonne
- Explique pourquoi le reweighing a un effet pour l'âge

Leçon

Retirer l'attribut sensible $\neq$ équité. L'interprétabilité permet de détecter la discrimination indirecte via les proxies.

Question : le modèle résiste-t-il au bruit ?

Protocole

- Numériques : $x_j + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0.2 \cdot \sigma_j)$
- Catégoriels : swap aléatoire ($p=0.1$)

ECE (cours incertitude) :

$$\text{ECE} = \sum_b \frac{|B_b|}{n} |\text{acc}_b - \text{conf}_b|$$

Mesure l'écart confiance / précision réelle.

Résultats

- Corrélation scores $r \approx 0.97$
- $\Delta\text{AUC} \approx -0.6$ points
- ECE stable (~ 0.05)
- Modèles fair **aussi robustes**

$\Rightarrow$ Modèle **stable**.

Les corrections d'équité n'amplifient pas la fragilité.

Ce qu'on a appris

- 1 **Les données sont biaisées** : taux de défaut différents entre groupes $\Rightarrow$ un bon modèle reproduira ces biais.
- 2 **Retirer l'attribut sensible ne suffit pas toujours** : pour le genre oui (proxies faibles), pour l'âge non (`duration_in_month` = proxy actif).
- 3 **Le reweighing est efficace quand il y a des proxies** : sans proxy, il ne change rien.
- 4 **Compromis DP/EO inévitable** : réduire $|\Delta DP|$ augmente $|\Delta EO|$ (théorème d'impossibilité).
- 5 **L'interprétabilité éclaire l'équité** : SHAP + corrélation = détection de proxies.
- 6 **Le modèle est robuste** au bruit, même après corrections.

Tout codé from scratch (numpy/pandas, sans scikit-learn).