

Analyse expérimentale : IA Responsable sur le German Credit Dataset

IA708 – Télécom Paris, 2026

1 Protocole expérimental

Le jeu UCI German Credit (Hofmann, 1994) contient 1000 demandes de crédit, 20 attributs (6 numériques, 14 catégoriels), cible binaire défaut/non-défaut (30 % / 70 %). Deux attributs sensibles : **genre** (extrait de `personal_status_sex`, 690 hommes / 310 femmes) et **âge** binarisé au seuil 25 ans (810 older / 190 younger). Les attributs sensibles sont initialement retirés des features ; nous discutons ce choix à la lumière d’une analyse de proxies (§4).

Modèle. Régression logistique L2 (`sklearn.LogisticRegression`, `liblinear`, $C = 1$, `max_iter = 1000`). **Convergence** vérifiée : log-loss train atteint 0.43 dès 10 itérations, val 0.56 (proche de la référence 0.5 attendue sur ce déséquilibre).

Données. Split stratifié 60/20/20 (train/val/test, `random_state=42`). Prétraitement `sklearn.ColumnTransformer` : `StandardScaler` pour les numériques, `OneHotEncoder` pour les catégoriels (56 colonnes finales). Le seuil de classification est calibré sur la val pour maximiser la balanced accuracy ($\tau = 0.18$).

Outils. `scikit-learn` (modèle, métriques, calibration, permutation importance), `fairlearn` (`MetricFrame`, `demographic_parity_difference`, `equalized_odds_difference`), `shap` (`LinearExplainer`). Reproductibilité par `papermill`.

2 Méthodes d’équité

Pré-traitement (reweighing). Poids $w_i = P(S=s_i) P(Y=y_i) / P(S=s_i, Y=y_i)$ rendant $S \perp Y$ dans la distribution pondérée.

Post-traitement (seuils par groupe). On cherche un seuil τ_g par groupe sensible égalisant le taux de sélection cible (Demographic Parity), calibré sur la validation puis appliqué au test.

3 Résultats principaux

Attribut	Modèle	AUC	BalAcc	$ \Delta DP $	$ \Delta EO $
Genre	Baseline	0.785	0.669	0.010	0.058
Genre	Reweighting	0.785	0.665	0.006	0.050
Genre	Baseline + PP	0.785	0.669	0.105	0.196
Genre	Reweighting + PP	0.785	0.669	0.128	0.230
Âge	Baseline	0.785	0.669	0.125	0.066
Âge	Reweighting	0.784	0.640	0.132	0.098
Âge	Baseline + PP	0.785	0.644	0.060	0.135
Âge	Reweighting + PP	0.784	0.650	0.069	0.221

TABLE 1 – Performance et équité sur le test (PP = post-processing par seuils par groupe).

Genre. Après retrait de `personal_status_sex`, le biais direct disparaît ($|\Delta DP| = 0.010$). Le reweighting n’a pas d’effet, mais le post-processing **crée** un biais artificiel ($|\Delta DP| = 0.105$, $|\Delta EO| = 0.196$) : sur un déséquilibre 690/310 et un test de 200, calibrer des seuils par groupe sur 200 exemples de validation se généralise mal.

Âge. Le biais reste significatif après retrait ($|\Delta DP| = 0.125$), cohérent avec les taux de défaut très différents (older 27 %, younger 42 %). Le post-processing réussit à réduire $|\Delta DP|$ à 0.060 mais **double** $|\Delta EO|$ (0.066 vers 0.135), illustration empirique du **théorème d’impossibilité** de Chouldechova [?] et Kleinberg et al. [?].

4 Interprétabilité et détection de proxies

Pour la régression logistique, $\phi_i(x) = w_i(x_i - \mathbb{E}[x_i])$ est exact (Lundberg & Lee [?], Corollary 1). SHAP et permutation importance concordent sur le top : `checking_status`, `credit_history`, `credit_amount`, `duration_in_month`.

Proxies multivariés. Suivant la recommandation de C. Laclau, on entraîne une régression logistique `features` $\rightarrow$ `attribut sensible` : **AUC = 0.86 pour l'âge**, AUC = 0.69 pour le genre. L'attribut sensible est largement reconstituable depuis les autres features. **Conséquence** : retirer l'attribut sensible des inputs ne suffit pas à garantir l'équité ; les méthodes "fairness through awareness" (le conserver pour mitiger explicitement) seraient théoriquement plus efficaces.

SHAP avant vs après retrait. Modèle **avec** attributs sensibles : AUC=0.781 ; **sans** (baseline) : AUC=0.785 (Δ négligeable). Δ Mean |SHAP| (sans – avec) montre que les features absorbent l'effet : `present_employment_since` (+0.036), `telephone` (+0.022), `credit_history` (+0.020). Confirmation graphique de l'AUC proxy=0.86 (figure dans le notebook et le beamer).

5 Quantification d'incertitude (substitut à la robustesse adversariale)

Sur conseil de l'enseignante, la robustesse a été remplacée par une **quantification d'incertitude par bootstrap** (cf. cours *Robustness and Uncertainty*). On entraîne $B = 200$ modèles sur des échantillons tirés avec remplacement, et on calcule des intervalles de confiance bootstrap sur toutes les métriques :

Métrique	Moyenne	Écart-type	IC 2.5 %	IC 97.5 %
AUC	0.764	0.019	0.723	0.795
BalAcc	0.682	0.023	0.637	0.726
Δ DP genre	0.035	0.028	0.001	0.105
Δ EO genre	0.089	0.044	0.017	0.176
Δ DP âge	0.104	0.046	0.020	0.202
Δ EO âge	0.086	0.048	0.018	0.194

TABLE 2 – Intervalles de confiance bootstrap (B=200, IC 95%).

L'IC95 % de | Δ DP| âge s'étend de 0.02 à 0.20. Le biais empirique de 0.125 est dans cet intervalle mais l'incertitude est très large (test de 200), ce qui plaide pour la **prudence méthodologique** : sur ce dataset, les écarts d'équité ne sont pas significatifs à un niveau précis.

Conclusion et limites

L'effet des corrections d'équité dépend fortement de la structure des proxies : reweighing inefficace pour le genre (proxies faibles, AUC proxy = 0.69), modificateur pour l'âge (proxies forts, AUC proxy = 0.86). Le théorème d'impossibilité est confirmé empiriquement. Le bootstrap montre que sur un dataset de 1 000 lignes, les conclusions sur l'équité doivent être nuancées par l'incertitude statistique (IC dépassant 0.15).

Limites : approche linéaire, reweighing simple, pas de robustesse adversariale (substitution par bootstrap). **Pistes** : essayer `fairlearn.ExponentiatedGradient` ou un transport optimal à la place du reweighing ; conserver l'âge et appliquer une mitigation in-processing.

Outils d'assistance. Des LLM (Claude, GPT) ont été utilisés pour l'aide à la rédaction du code (pipeline `sklearn`, intégration `fairlearn/shap`) et la structuration. Toutes les décisions méthodologiques (choix des métriques, interprétation, conception du bootstrap) ont été prises et discutées en équipe.

Références A. Chouldechova, *Fair prediction with disparate impact*, Big Data 5(2), 2017, arXiv:1703.00056 ; J. Kleinberg et al., *Inherent trade-offs in the fair determination of risk scores*, ITCS 2017, arXiv:1609.05807 ; S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions*, NeurIPS 2017, arXiv:1705.07874 (Linear SHAP, Corollary 1, p. 6) ; F. Kamiran, T. Calders, *Data preprocessing techniques for classification without discrimination*, KAIS 33(1), 2012, doi:10.1007/s10115-011-0463-8 ; R. K. E. Bellamy et al., *AI Fairness 360*, IBM 2018, arXiv:1810.01943 ; M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning*, NeurIPS 2016, arXiv:1610.02413 ; B. Efron, *Bootstrap methods*, Annals of Statistics 7(1), 1979, doi:10.1214/aos/1176344552 ; C. Guo et al., *On Calibration of Modern Neural Networks*, ICML 2017, arXiv:1706.04599 ; S. Bird et al., *Fairlearn*, Microsoft 2020, fairlearn.org.