

IA Responsable, German Credit Dataset

Rapport accompagnant le notebook `responsiveAI-german-credit_rendu.ipynb`

IA708 — Télécom Paris, 2026

Étudiants :

Julien GIMENEZ <julien.gimenez@telecom-paris.fr>

Hugo FANCHINI <hugo.fanchini@telecom-paris.fr>

Paul CINTRA <paul.cintra@telecom-paris.fr>

Yimou ZHANG <yimou.zhang@telecom-paris.fr>

Zaher HAMADEH <zaher.hamadeh@telecom-paris.fr>

Résumé

Ce document accompagne le notebook `responsiveAI-german-credit_rendu.ipynb` et détaille chaque étape du parcours d'analyse. L'objectif : évaluer un modèle de scoring crédit sous trois angles — **équité**, **interprétabilité** et **quantification d'incertitude** (qui remplace la robustesse adversariale, sur conseil de l'enseignante) — en partant des données brutes et en progressant vers des conclusions argumentées. Stack utilisé : `scikit-learn`, `fairlearn`, `shap` ; reproductibilité via `papermill`. Ce parcours suit la structure du cours IA708.


Table des matières

1	Vue d'ensemble du parcours	1
2	Les données : point de départ	2
3	Exploration : les biais préexistent dans les données	2
3.1	Extraction des attributs sensibles	2
3.2	Répartition des groupes	2
3.3	Ce que le notebook montre	3
4	Préparation des données	3
4.1	Retrait des attributs sensibles	3
4.2	Prétraitement : <code>sklearn ColumnTransformer</code>	3
4.3	Split stratifié 60/20/20	3
5	Modèle de base : régression logistique <code>sklearn</code>	4
5.1	Le modèle	4
5.2	Entraînement (<code>sklearn</code>)	4
5.3	Vérification de convergence (feedback équipe)	4
5.4	Seuil de décision	4
5.5	Comparaison à des baselines triviaux	5

6	Métriques : mesurer ce qui compte	5
6.1	Métriques de performance	6
6.2	Métriques d'équité (cf. cours fairness)	6
6.3	Évaluation du baseline	6
6.4	Audit intersectionnel : combinaisons genre $\times$ âge	6
7	Reweighting : correction en pré-traitement	7
7.1	Principe	7
7.2	Calcul concret sur un mini-exemple	8
8	Seuils par groupe : correction en post-traitement	8
8.1	Principe	8
8.2	Illustration intuitive	9
9	Comparaison : 4 configurations	9
9.1	Tableau de résultats	9
9.2	Analyse détaillée	9
9.3	Post-processing officiel : fairlearn ThresholdOptimizer	10
9.4	Le théorème d'impossibilité en action	10
9.5	Ce que le notebook montre	11
10	Interprétabilité : comprendre les décisions	11
10.1	SHAP linéaire exact	11
10.2	Importance par permutation	12
10.3	Détection de proxies (deux approches)	12
10.4	SHAP : avant vs après retrait des attributs sensibles	12
11	Quantification d'incertitude : peut-on faire confiance aux chiffres ?	13
11.1	Protocole bootstrap	13
11.2	Résultats	13
12	Conclusion : ce qu'on a appris	14

1 Vue d'ensemble du parcours

Avant d'entrer dans le code, comprenons la **logique du parcours**. Chaque étape répond à une question qui motive naturellement la suivante :



Chaque flèche correspond à une **transition motivée** : on ne passe à l'étape suivante que parce que la précédente a soulevé une question. C'est cette logique narrative que nous allons dérouler.

2 Les données : point de départ

Étape 1 — Pourquoi ces données ?

Le **German Credit Dataset** (UCI Statlog, Hofmann 1994) est un cas d'école en IA responsable : 1 000 demandes de crédit décrites par 20 attributs. La cible est binaire : **défaut de paiement** (1) ou non (0). Le scoring crédit est une décision à fort impact humain — un refus injuste peut affecter la vie entière d'un demandeur.

Chargement. Le fichier `german.data` est un CSV séparé par espaces, sans entête. La cible originale est codée 1 (bon) / 2 (mauvais) ; on la transforme en `default` $\in \{0, 1\}$.

Caractéristique	Valeur	Proportion
Bon payeur (défaut = 0)	700	70 %
Mauvais payeur (défaut = 1)	300	30 %
Features numériques	7	—
Features catégorielles	13	—

TABLE 1 – Vue d'ensemble du dataset.

Premiers constats. Le déséquilibre 70/30 est important : un modèle qui prédirait toujours « bon » aurait 70 % d'accuracy. C'est pourquoi on utilisera des métriques adaptées (§6).

3 Exploration : les biais préexistent dans les données

Étape 2 — Y a-t-il déjà des biais ?

Avant même de construire un modèle, on examine si les données reflètent des disparités entre groupes. Si oui, tout modèle performant les **reproduira**.

3.1 Extraction des attributs sensibles

On définit deux attributs sensibles, conformément au cours *fairness* :

- **Genre** : extrait de la colonne `personal_status_sex`. Les codes A91, A93, A94 correspondent aux hommes ; A92, A95 aux femmes.
- **Âge** : binarisé au seuil de 25 ans. Adulte (> 25) vs jeune (≤ 25).

3.2 Répartition des groupes

Groupe	Effectif	Taux bon	Taux défaut
Homme	690 (69 %)	72 %	28 %
Femme	310 (31 %)	65 %	35 %
Adulte (> 25)	810 (81 %)	72 %	28 %
Jeune (≤ 25)	190 (19 %)	60 %	40 %

TABLE 2 – Taux de défaut par groupe — biais préexistants dans les données.

Leçon clé

Les femmes ont un taux de défaut plus élevé que les hommes (+7 points), et les jeunes plus que les adultes (+12 points). Ces écarts ne sont pas nécessairement « vrais » — ils peuvent refléter des biais historiques dans l’attribution des crédits. Un modèle entraîné sur ces données reproduira et potentiellement amplifiera ces disparités.

3.3 Ce que le notebook montre

Le notebook produit trois graphiques côte à côte :

1. **Distribution de la cible** — barre verte (bon) vs rouge (mauvais) : on voit le déséquilibre 70/30.
2. **Distribution par genre** — les hommes sont surreprésentés (69 %).
3. **Histogramme d’âge** avec le seuil 25 ans — la majorité sont des adultes, les jeunes sont une minorité (19 %).

Ces visualisations motivent la suite : comment construire un modèle qui soit performant *et* équitable ?

4 Préparation des données

Étape 3 — Comment préparer les données pour le modèle ?

Trois décisions clés : (1) retirer les attributs sensibles des features, (2) encoder les variables, (3) séparer train/validation/test.

4.1 Retrait des attributs sensibles

On retire `personal_status_sex` et `age_in_years` des features d’entraînement.

Attention : proxy

Retirer la colonne ne suffit pas toujours. D’autres features peuvent être **corrélées** à l’attribut sensible et servir de **proxy** — le modèle peut alors discriminer *indirectement*. On vérifiera cela à l’étape 9 (SHAP).

4.2 Prétraitement : sklearn ColumnTransformer

- **Numériques** (6 colonnes) : `StandardScaler` (z-score), μ et σ calculés sur le train uniquement.
- **Catégorielles** (12 colonnes) : `OneHotEncoder(handle_unknown="ignore")`.

Résultat : 56 features numériques après encodage.

Le préprocesseur est **fité sur le train** et **appliqué** au val/test — pas de fuite d'information.

```
preprocessor = ColumnTransformer([
    ("num", StandardScaler(), NUMERIC),
    ("cat", OneHotEncoder(handle_unknown="ignore", sparse_output=False), CATEG),
])
X_tr = preprocessor.fit_transform(features.iloc[idx_tr])
X_va = preprocessor.transform(features.iloc[idx_va])
X_te = preprocessor.transform(features.iloc[idx_te])
```

4.3 Split stratifié 60/20/20

La répartition est stratifiée par la cible : chaque sous-ensemble conserve le ratio 70/30. Le seed est fixé (`rng = default_rng(42)`) pour la reproductibilité.

	Train	Validation	Test
Taille	~600	~200	~200
Rôle	Entraînement	Choix du seuil, PP	Évaluation finale

5 Modèle de base : régression logistique sklearn

Étape 4 — Quel modèle, et comment l'entraîner ?

On utilise une régression logistique de `scikit-learn`. Pourquoi ce modèle ? (1) C'est interprétable (un coefficient par feature, formule SHAP exacte), (2) bien adapté aux données tabulaires, (3) calibré par défaut.

5.1 Le modèle

La régression logistique modélise la probabilité de défaut :

$$P(\text{défaut} = 1 \mid x) = \sigma(w^\top x + b) \quad \text{avec} \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

où $w \in \mathbb{R}^d$ est le vecteur de poids et b le biais.

5.2 Entraînement (sklearn)

La perte est la **cross-entropy binaire** avec pénalisation L2 :

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n s_i \left[y_i \ln p_i + (1 - y_i) \ln(1 - p_i) \right] + \frac{1}{2C} \|w\|^2$$

où s_i est le poids de l'exemple (utilisé pour le reweighing, $s_i = 1$ pour le baseline) et $C = 1$ est l'inverse de la régularisation (forme sklearn).

Hyperparamètre	Valeur
Solver	<code>liblinear</code> (descente coordonnée)
Pénalisation	L2, $C = 1$
Max iterations	1000 (convergence à ~ 10 itérations)
Random state	42

TABLE 3 – Hyperparamètres de `LogisticRegression` sklearn.

5.3 Vérification de convergence (feedback équipe)

L'équipe attendait une convergence à partir de 100 itérations et une log-loss autour de 0.5. **Mesure :**

- Log-loss train final : **0.43**
- Log-loss val : **0.56** (proche de 0.5 attendu sur déséquilibre 70/30)
- Convergence atteinte dès 10 itérations (`liblinear` converge très vite sur ce dataset)

5.4 Seuil de décision

On ne fixe pas le seuil à 0.5. On balaye $\tau \in [0.1, 0.9]$ et on choisit celui qui maximise la **balanced accuracy** sur la validation :

$$\text{BalAcc} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right)$$

Ce choix est motivé par le déséquilibre 70/30 : un seuil fixe à 0.5 favorise la classe majoritaire. Résultat : $\tau = 0.18$ sur la validation.

5.5 Comparaison à des baselines triviaux

Pour situer la performance du baseline (AUC = 0.785), on la compare à trois prédicteurs naïfs : un classifieur aléatoire stratifié, une règle "younger $\Rightarrow$ défaut" et une règle basée sur `checking_status` (la feature la plus importante selon SHAP).

Modèle	AUC test
Aléatoire stratifié (DummyClassifier)	0.524
Règle "younger $\Rightarrow$ défaut"	0.581
Règle " <code>checking_status</code> < 0"	0.661
Régression logistique (baseline)	0.785

TABLE 4 – Comparaison à des baselines triviaux.




FIGURE 1 – Régression logistique vs trois baselines triviaux.

Leçon

La régression logistique apporte un gain de **+0.124** d'AUC par rapport à la meilleure règle naïve (`checking_status`). Ce gain justifie l'usage du modèle ML par rapport à une heuristique métier simple. Inversement, on note qu'une règle uniquement basée sur l'âge atteint déjà 0.58 d'AUC : l'âge porte un signal réel mais limité, et l'utiliser seul serait à la fois insuffisant et discriminatoire.

6 Métriques : mesurer ce qui compte

Étape 5 — Comment évaluer performance ET équité ?

La performance seule ne suffit pas. Il faut aussi mesurer si le modèle traite les groupes de manière équitable. On définit les deux familles de métriques utilisées dans tout le reste du parcours.

6.1 Métriques de performance

Métrique	Pourquoi ?
AUC ROC	Invariante au seuil. Mesure la capacité à séparer les classes.
Balanced Acc.	$\frac{1}{2}(\text{TPR} + \text{TNR})$. Adaptée au déséquilibre (vs accuracy naïve).
Coût métier	$5 \cdot \text{FN} + 1 \cdot \text{FP}$ (matrice UCI : approuver un mauvais crédit coûte $5 \times$ plus).

6.2 Métriques d'équité (cf. cours fairness)

Soit S l'attribut sensible, Y la cible, $\hat{Y}$ la prédiction.

Critère	Définition	Signification
Demographic Parity	$ P(\hat{Y}=1 S=0) - P(\hat{Y}=1 S=1) $	Même taux de sélection
Equal Opportunity	$ \text{TPR}_{S=0} - \text{TPR}_{S=1} $	Même rappel sur les vrais positifs

Un modèle parfaitement équitable aurait $|\Delta \text{DP}| = 0$ et $|\Delta \text{EO}| = 0$. En pratique, c'est impossible simultanément (§9.4).

6.3 Évaluation du baseline

Le notebook affiche les résultats du baseline :

Attribut	Groupe	Taux sélection	TPR	Effectif test
Genre	Homme	≈ 0.41	≈ 0.70	~ 140
	Femme	≈ 0.50	≈ 0.74	~ 60
Âge	Adulte	≈ 0.42	≈ 0.77	~ 160
	Jeune	≈ 0.51	≈ 0.59	~ 40

TABLE 5 – Métriques d'équité du baseline (valeurs approchées, dépendent du seed).

Constat

Le baseline n'est pas équitable. Pour l'âge, le $|\Delta DP| = 0.125$ et le $DI = 0.69$ (sous le seuil légal US 0.8). Pour le genre, biais quasi nul après retrait de `personal_status_sex`. Cela justifie l'étape suivante : auditer les sous-groupes intersectionnels avant de mitiger.

6.4 Audit intersectionnel : combinaisons genre $\times$ âge

L'audit séparé (genre seul, âge seul) peut masquer des biais qui n'apparaissent qu'à l'intersection. On combine les deux attributs en un attribut à 4 niveaux et on ré-applique `fairness_summary`. Référence : cours `fairness-ms-1.pdf` (slide sur les biais multivariés).

Sous-groupe	n	Approval rate	TPR
female_older	36	0.44	0.85
male_older	120	0.38	0.85
female_younger	25	0.28	0.92
male_younger	19	0.26	0.86

TABLE 6 – Audit intersectionnel sur les 4 sous-groupes `genre_age`.

Synthèse des écarts agrégés vs intersectionnels :

Axe	$ \Delta DP $	$ \Delta EO $	DI
Genre seul	0.010	0.058	0.97
Âge seul	0.125	0.066	0.69
Intersection	0.181	0.222	0.59

TABLE 7 – Comparaison des écarts d'équité : agrégés vs intersectionnel.




FIGURE 2 – Approval rate par sous-groupe (gauche) et comparaison des écarts agrégés vs intersectionnel (droite).

Leçon

L'intersection révèle un biais **1.5× plus marqué** que l'analyse par axe séparé. $DI = 0.59$ est gravement sous le seuil légal US 0.8. Ce sont les **jeunes hommes** qui ont le taux d'octroi le plus bas (0.26) sur ce dataset, contrairement à l'intuition initiale "les jeunes femmes sont les plus défavorisées". À interpréter avec prudence vu les petits effectifs ($n = 19, 25$).

7 Reweighting : correction en pré-traitement

Étape 6 — Peut-on corriger les biais sans changer le modèle ?

Le **reweighting** (cf. cours fairness-mitigation) est une méthode de pré-traitement : on repondère les exemples d'entraînement pour équilibrer la relation entre S et Y .

7.1 Principe

L'idée est simple : si un sous-groupe est sous-représenté dans une classe, on augmente son poids. Formellement :

$$w_i = \frac{P(S = s_i) \cdot P(Y = y_i)}{P(S = s_i, Y = y_i)}$$

Ce poids rend $S \perp Y$ dans la distribution pondérée.

7.2 Calcul concret sur un mini-exemple

Imaginons un mini-entraînement de 100 personnes, avec les comptages croisés suivants :

	$Y = 0$ (bon)	$Y = 1$ (défaut)	Total S
$S = \text{Homme}$	50	20	70
$S = \text{Femme}$	20	10	30
Total Y	70	30	100

TABLE 8 – Mini-exemple : effectifs croisés.

Calcul des probabilités : $P(S=H) = 0,7$, $P(S=F) = 0,3$, $P(Y=0) = 0,7$, $P(Y=1) = 0,3$.

Calcul des poids pour chaque cellule :

- $(H, Y=0) : w = \frac{0,7 \times 0,7}{0,50} = 0,98$ (légèrement diminué, surreprésenté)
- $(H, Y=1) : w = \frac{0,7 \times 0,3}{0,20} = 1,05$ (légèrement augmenté)
- $(F, Y=0) : w = \frac{0,3 \times 0,7}{0,20} = 1,05$ (femmes « bonnes » : sous-repr.)
- $(F, Y=1) : w = \frac{0,3 \times 0,3}{0,10} = 0,90$ (femmes en défaut : surrepr.)

Après pondération, $S \perp Y$: la corrélation entre genre et défaut disparaît dans la perte d'entraînement.

Direction générale

Privilégié “mauvais” et non-privilégié “bon” reçoivent $w > 1$. Privilégié “bon” et non-privilégié “mauvais” reçoivent $w < 1$. C'est exactement ce qu'il faut pour casser la corrélation $S-Y$.

On entraîne ensuite un **nouveau modèle** avec ces poids (paramètre `sample_weight` dans `train_logreg`). Un modèle repondéré est entraîné **par attribut sensible**.

8 Seuils par groupe : correction en post-traitement

Étape 7 — Peut-on corriger sans ré-entraîner ?


Le post-traitement ajuste le seuil de classification **séparément par groupe** pour égaliser le taux de sélection (Demographic Parity).

8.1 Principe

Au lieu d'un seuil global τ , on calibre τ_{g_0} et τ_{g_1} sur la validation pour que :

$$P(\hat{Y}=1 \mid S=g_0) \approx P(\hat{Y}=1 \mid S=g_1)$$

8.2 Illustration intuitive



Les deux groupes ont des distributions de scores différentes. En appliquant le même seuil, on sélectionnerait des proportions différentes. L'ajustement de seuil par groupe rééquilibre cela.

Avantage

Pas de ré-entraînement. On utilise le même modèle, seul le seuil change. Très rapide.

Limite

Calibré sur ~ 200 exemples : seuils potentiellement instables. Et juridiquement, des seuils différents par groupe peuvent être problématiques.

9 Comparaison : 4 configurations

Étape 8 — Quel est l'effet réel des corrections ?

On compare systématiquement 4 configurations pour chaque attribut sensible : (1) Baseline, (2) Reweighing, (3) Baseline + post-processing, (4) Reweighing + post-processing.

9.1 Tableau de résultats

Attr.	Configuration	AUC	BalAcc	$ \Delta DP $	$ \Delta EO $
Genre	Baseline	0.785	0.669	0.010	0.058
Genre	Reweighing	0.785	0.665	0.006	0.050
Genre	Baseline + PP	0.785	0.669	0.105	0.196
Genre	Reweighing + PP	0.785	0.669	0.128	0.230
Âge	Baseline	0.785	0.669	0.125	0.066
Âge	Reweighing	0.784	0.640	0.132	0.098
Âge	Baseline + PP	0.785	0.644	0.060	0.135
Âge	Reweighing + PP	0.784	0.650	0.069	0.221

TABLE 9 – Performance et équité sur le test (PP = post-processing par seuils/groupe).

9.2 Analyse détaillée

Genre — biais quasi nul, le PP crée un biais artificiel. Après retrait de `personal_status_sex`, $|\Delta DP| = 0.010$: pas de discrimination directe détectable. Le reweighing n'a quasi aucun effet ($0.010 \rightarrow 0.006$). **En revanche**, le post-processing par seuils par groupe **crée** un biais artificiel ($|\Delta DP| = 0.105$, $|\Delta EO| = 0.196$). Pourquoi ? Le calibrage des seuils sur 200 exemples de validation généralise mal au test (200 exemples).

Âge — biais initial significatif, compromis DP/EO clair. $|\Delta DP| = 0.125$ persiste après retrait de `age_in_years`, cohérent avec les taux de défaut très différents (younger 42 % vs older 27 %). Le post-processing réduit $|\Delta DP|$ de 0.125 à **0.060** (amélioration), **mais** $|\Delta EO|$ **double** : $0.066 \rightarrow 0.135$. C'est l'illustration empirique parfaite du théorème d'impossibilité.

9.3 Post-processing officiel : fairlearn ThresholdOptimizer

Notre code maison égalise le taux de sélection (proxy de Demographic Parity). La librairie `fairlearn` fournit l'implémentation officielle de Hardt et al. 2016 qui peut imposer plusieurs contraintes (DP, EO, equalized_odds), via une optimisation linéaire des seuils par groupe.

Stratégie	BalAcc	$ \Delta DP $	$ \Delta EO $	DI
Baseline (sans PP)	0.669	0.125	0.066	0.69
PP maison (Demographic Parity)	0.644	0.060	0.135	0.86
fairlearn ThresholdOpt (EO)	0.596	0.060	0.300	0.94

TABLE 10 – Comparaison de 3 stratégies de post-processing sur l'âge.




FIGURE 3 – Équité (gauche) et performance (droite) pour 3 stratégies de post-processing.

Leçon : limite des méthodes optimisées sur petit dataset


Sur ce dataset (val = 200, test = 200), **ThresholdOptimizer dégrade** $|\Delta EO|$ ($0.066 \rightarrow 0.300$) au lieu de l'améliorer. Le mécanisme : il randomise les décisions pour atteindre la contrainte, et calibré sur 200 lignes, ne généralise pas. Sur datasets plus grands, il améliore systématiquement (Hardt et al. 2016). **Conclusion** : sur petit dataset, mieux vaut une heuristique simple (PP maison) qu'une optimisation officielle qui exige plus de données.

9.4 Le théorème d'impossibilité en action

Théorème d'impossibilité (Chouldechova 2017, Kleinberg 2016)

Il est **mathématiquement impossible** de satisfaire simultanément Demographic Parity, Equal Opportunity et calibration, sauf si les taux de base sont égaux entre groupes — ce qui n'est pas le cas ici.

Visualisation géométrique du compromis.



Les configurations du modèle se déplacent sur une **frontière de Pareto** : on ne peut améliorer une dimension qu'au prix d'une autre. Le point idéal (0,0) est inaccessible.

À retenir

Nos résultats sur l'âge illustrent ce théorème : réduire $|\Delta DP|$ **augmente** $|\Delta EO|$. Ce n'est pas un échec — c'est une **limite fondamentale**. En pratique, il faut choisir le critère selon le contexte métier (« recall » pour la médecine, « selection rate » pour le recrutement, etc.).

9.5 Ce que le notebook montre

Le graphique en **scatter plot** (AUC vs $|\Delta DP|$) visualise ce compromis : les points se déplacent vers la gauche (plus équitable) au prix d'un léger recul en performance ou d'une hausse de $|\Delta EO|$.

10 Interprétabilité : comprendre les décisions

Étape 9 — Pourquoi le modèle prend-il ces décisions ?

L'interprétabilité est essentielle pour (1) expliquer les décisions aux utilisateurs, (2) détecter la discrimination indirecte via les proxies. Deux méthodes complémentaires sont utilisées.

10.1 SHAP linéaire exact

Pour un modèle linéaire, les **valeurs de Shapley** (cf. cours interprétabilité) ont une forme fermée exacte :

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}_{\text{train}}[x_i])$$

où w_i est le coefficient du modèle et $\mathbb{E}_{\text{train}}[x_i]$ la moyenne de la feature i sur le train. La contribution est signée : positive si la feature pousse vers le défaut, négative sinon. Pour les features catégorielles (one-hot), on somme les contributions des dummies associées.

Top features (baseline). Les features les plus influentes sont typiquement :

1. `checking_status` — le statut du compte courant
2. `duration_in_month` — la durée du crédit
3. `credit_amount` — le montant
4. `credit_history` — l'historique
5. `savings_account_bonds` — l'épargne

10.2 Importance par permutation

Méthode complémentaire : on mélange aléatoirement une colonne et on mesure la **chute d'AUC**. Si l'AUC diminue beaucoup, la feature est importante. On répète 10 fois par feature pour stabiliser.

Convergence des deux méthodes

SHAP (local $\rightarrow$ global) et permutation (global) convergent sur le classement des features. C'est rassurant : les deux approches donnent la même image des décisions du modèle.

10.3 Détection de proxies (deux approches)

Un **proxy** est une feature qui permet de prédire l'attribut sensible. Deux méthodes :

1. Corrélation univariée ($|r|$). Pour chaque feature, on calcule la corrélation absolue avec l'attribut sensible binarisé. Rapide mais ignore les interactions multivariées.

2. Régression logistique features $\rightarrow$ attribut sensible (approche Charlotte). On entraîne un modèle pour prédire l'attribut sensible à partir des autres features. **Si l'AUC $> 0.5 + \epsilon$, l'attribut est reconstituable $\Rightarrow$ proxy multivarié actif.**

Attribut	AUC proxy (multivarié)	Interprétation
Genre	0.69	Signal proxy modéré
Âge	0.86	Très fortement restructurable

TABLE 11 – Détection multivariée de proxies (régression logistique).

Recommandation Charlotte : retirer l’attribut sensible ne suffit pas. La meilleure stratégie est de **conserver l’attribut** et de l’utiliser explicitement comme pondération dans une mitigation in-processing (*fairness through awareness*).

10.4 SHAP : avant vs après retrait des attributs sensibles

Pour visualiser concrètement le mécanisme de proxy, on entraîne un modèle **avec age_in_years** et **personal_status_sex** en plus des autres features, et on compare l’importance SHAP par feature avec le modèle **sans** (notre baseline).

Modèle	AUC test
Avec attributs sensibles	0.781
Sans attributs sensibles (baseline)	0.785
Coût du retrait	−0.004 (négligeable)

TABLE 12 – Coût en performance du retrait des attributs sensibles.

Top 5 features qui absorbent l’effet après retrait ($\Delta \text{Mean } |\text{SHAP}| = \text{sans} - \text{avec}$, plus c’est haut plus la feature « hérite » de l’effet des attributs sensibles) :

Feature	Avec	Sans	Δ
present_employment_since	0.171	0.207	+0.036
telephone	0.216	0.238	+0.022
credit_history	0.470	0.489	+0.020
duration_in_month	0.278	0.289	+0.011
number_of_existing_credits	0.140	0.150	+0.009

TABLE 13 – Features absorbant l’effet des attributs sensibles (top 5 par ΔSHAP).

Leçon

SHAP rend visible ce que la régression proxy mesure numériquement. Quand on retire l’attribut sensible, son influence ne disparaît pas : elle se **redistribue** aux features les plus corrélées. C’est l’illustration la plus claire de la **discrimination indirecte**.

Leçon fondamentale

La détection de proxies **explique** pourquoi le reweighing fonctionne pour l’âge mais pas pour le genre. L’interprétabilité n’est pas un bonus — c’est un outil essentiel pour comprendre et diagnostiquer les problèmes d’équité.

11 Quantification d'incertitude : peut-on faire confiance aux chiffres ?

Étape 10 — Les biais mesurés sont-ils statistiquement significatifs ?

Sur conseil de l'enseignante (Charlotte Laclau), nous remplaçons la robustesse adversariale par une **quantification d'incertitude par bootstrap** (cf. cours *Robustness and Uncertainty*, G. Franchi). Le bootstrap mesure la stabilité des décisions face à la variabilité des données.

11.1 Protocole bootstrap

On entraîne $B = 200$ modèles sur des échantillons tirés avec remplacement du jeu d'entraînement, puis on agrège les résultats. C'est l'approche d'**ensemble** la plus simple, analogue classique des *Deep Ensembles* de Lakshminarayanan et al. (2017).

- **Intervalle de confiance sur les métriques** : quantiles 2.5 % et 97.5 % des B valeurs.
- **Intervalle de prédiction par individu** : quantiles des scores des B modèles.
- L'incertitude **épistémique** est capturée par le désaccord entre membres de l'ensemble.

11.2 Résultats

Métrique	Moyenne	σ	IC 2.5 %	IC 97.5 %
AUC	0.764	0.019	0.723	0.795
Balanced Accuracy	0.682	0.023	0.637	0.726
$ \Delta DP $ genre	0.035	0.028	0.001	0.105
$ \Delta EO $ genre	0.089	0.044	0.017	0.176
$ \Delta DP $ âge	0.104	0.046	0.020	0.202
$ \Delta EO $ âge	0.086	0.048	0.018	0.194

TABLE 14 – Intervalles de confiance bootstrap ($B=200$, IC 95 %).

Leçon

L'IC95 % de $|\Delta DP|$ âge s'étend de 0.02 à 0.20. Le biais empirique de 0.125 est dans cet intervalle, mais l'incertitude est très large (test de 200) $\Rightarrow$ **prudence méthodologique**. Sur ce dataset, les écarts d'équité ne sont pas significatifs à un niveau précis.

12 Conclusion : ce qu'on a appris


Étape 11 — Quelles leçons tirer ?

Le parcours complet nous enseigne six leçons fondamentales, qui relient les trois piliers du cours (équité, interprétabilité, quantification d'incertitude).

1. **Les données sont biaisées sur l'âge**, pas sur le genre. Younger 42 % vs older 27 % de défaut, alors que le genre montre $|\Delta DP| = 0.010$ après retrait de `personal_status_sex`.
2. **Retirer l'attribut sensible ne suffit pas (approche Charlotte)**. La régression logistique `features` $\rightarrow$ âge a un **AUC = 0.86** : l'âge est largement reconstituable depuis `housing`, `employment`, `job`... Pour le genre, $AUC = 0.69$ (signal modéré).
3. **Le reweighing modifie peu le modèle linéaire** sur ce dataset. Combiné au post-processing, il réduit $|\Delta DP|$ âge mais crée des effets non triviaux sur EO.
4. **Le compromis DP/EO est inévitable**. Le post-processing réduit $|\Delta DP|$ âge ($0.125 \rightarrow 0.060$)


mais **double** $|\Delta EO|$ ($0.066 \rightarrow 0.135$). C'est le théorème d'impossibilité — pas un échec de la méthode.

5. **L'interprétabilité éclaire l'équité.** SHAP + permutation + régression sur l'attribut sensible = détection multi-niveaux des proxies.
6. **L'incertitude statistique est large.** L'IC95 % bootstrap de $|\Delta DP|$ âge va de **0.02 à 0.20**. Sur un dataset de 1000 lignes, les conclusions sur l'équité doivent être nuancées par l'incertitude.



Les trois piliers sont interdépendants : l'interprétabilité révèle les problèmes d'équité, la quantification d'incertitude précise la confiance qu'on peut leur accorder.

Arbre de décision : que faire selon la situation ?



Code : `scikit-learn + fairlearn + shap`, reproductibilité via `papermill`.