

IA Responsable, German Credit Dataset

Rapport accompagnant responsiveAI-german-credit_rendu.ipynb

IA708 — Télécom Paris, 2026

Étudiants :

Julien GIMENEZ <julien.gimenez@telecom-paris.fr>

Hugo FANCHINI <hugo.fanchini@telecom-paris.fr>

Paul CINTRA <paul.cintra@telecom-paris.fr>

Yimou ZHANG <yimou.zhang@telecom-paris.fr>

Zaher HAMADEH <zaher.hamadeh@telecom-paris.fr>

Résumé

Étude d'un modèle de scoring crédit (UCI German Credit, 1000 lignes) sous l'angle de l'IA responsable. On évalue la régression logistique baseline sur trois axes : **équité** (Demographic Parity, Equal Opportunity, Disparate Impact, audit intersectionnel), **interprétabilité** (SHAP global et local, détection de proxies), et **quantification d'incertitude** (bootstrap, $B = 200$, en substitution à la robustesse adversariale sur conseil de l'enseignante). Stack : `scikit-learn`, `fairlearn`, `shap`, exécution reproductible via `papermill`.

Table des matières

1	Données et préparation	1
1.1	Dataset et attributs sensibles	1
1.2	Biais bruts	1
1.3	Préparation	2
2	Modèle baseline : régression logistique	2
2.1	Choix du modèle	2
2.2	Performance globale	2
2.3	Coût métier (matrice UCI)	2
3	Audit d'équité	3
3.1	Métriques utilisées	3
3.2	Audit par axe	3
3.3	Audit intersectionnel	3
4	Atténuation des biais	4
4.1	Pré-traitement : reweighing (Kamiran & Calders 2012)	4
4.2	Post-traitement : seuils par groupe (Hardt et al. 2016)	4
4.3	Comparaison des 4 configurations	5
5	Interprétabilité	5

5.1	SHAP global	5
5.2	SHAP local : explication individuelle	6
5.3	Détection de proxys	6
5.4	Comparaison SHAP : avant vs après retrait	7
5.5	Performance avec vs sans attributs sensibles	7
6	Quantification d’incertitude	8
6.1	Bootstrap	8
6.2	Intervalle de prédiction par individu	9
7	Tableau de bord récapitulatif	9
8	Conclusion	10
8.1	Résultats principaux	10
8.2	Choix méthodologiques	10
8.3	Limites	10
8.4	Outils d’assistance utilisés	10

1 Données et préparation

1.1 Dataset et attributs sensibles

UCI Statlog German Credit (Hofmann, 1994) : 1000 lignes, 20 attributs (6 numériques, 14 catégoriels). Les codes **Axx** sont traduits en libellés français. Cible binaire : défaut de paiement (30 %) vs bon payeur (70 %).

Deux attributs sensibles sont définis :

- **Genre** (depuis `personal_status_sex`) : 690 hommes, 310 femmes.
- **Âge** binarisé au seuil 25 ans, convention de la littérature (Kamiran & Calders 2012, AIF360) : 810 *older*, 190 *younger*.

1.2 Biais bruts

Les taux de défaut diffèrent fortement entre groupes :

Groupe	P(bon)	P(défaut)
Homme	0.72	0.28
Femme	0.65	0.35
Older	0.73	0.27
Younger	0.58	0.42

TABLE 1 – Taux de défaut conditionnel par groupe sensible (données brutes).

Un modèle qui copie ces statistiques sera mécaniquement biaisé. C’est l’enjeu central du projet.

1.3 Préparation

`ColumnTransformer` (Pedregosa et al. 2011) combine `StandardScaler` pour les numériques et `OneHotEncoder` pour les catégorielles : 56 features finales.

Split stratifié 60/20/20 (train/val/test, `random_state=42`). Les attributs sensibles (`personal_status_sex`, `age_in_years`) sont retirés des features ; on verra que ce retrait ne suffit pas à supprimer leur influence (§5.3).

2 Modèle baseline : régression logistique

2.1 Choix du modèle

`LogisticRegression` (sklearn, solver `liblinear`, $C = 1$, L_2). Le modèle :

$$P(\text{défaut} = 1 \mid x) = \sigma(w^\top x + b)$$

Trois raisons à ce choix : (1) interprétabilité native, (2) formule SHAP exacte (Lundberg & Lee 2017, Corollary 1), (3) naturellement bien calibré sur petit dataset.

Le seuil de classification $\tau = 0.18$ est choisi pour maximiser la balanced accuracy sur la validation. Convergence : 6 itérations effectives.

2.2 Performance globale

Métrique	Valeur (test)
AUC ROC	0.785
Average Precision (AP)	0.607
Balanced Accuracy ($\tau = 0.18$)	0.669
Confusion : TN / FP / FN / TP	66 / 74 / 8 / 52
TPR (rappel défaut)	86.7 %
PPV (précision)	41.3 %

TABLE 2 – Métriques de performance du baseline sur le test (200 lignes).




FIGURE 1 – Matrice de confusion (gauche), courbe ROC (centre, $AUC = 0.785$), courbe Precision-Recall (droite, $AP = 0.607$). Au seuil 0.18, le modèle privilégie la détection des défauts ($TPR = 87\%$) au prix d'un taux de faux positifs élevé.

2.3 Coût métier (matrice UCI)

UCI fournit une matrice de coût : un défaut approuvé (FN) coûte $5\times$ plus qu'un bon refusé (FP). On compare deux seuils :

- `thr_balacc` = 0.18 : maximise la balanced accuracy. Coût test = 114.
- `thr_cost` = 0.14 : minimise $5 \cdot FN + 1 \cdot FP$. Coût test = 122.

Le rappel des défauts (TPR) est identique pour les deux seuils. Sur petit dataset, la calibration coût-optimale par validation se généralise mal au test.

3 Audit d'équité

3.1 Métriques utilisées

Calculs via `fairlearn.metrics.MetricFrame` (Bird et al. 2020) :

- $|\Delta DP|$ *Demographic Parity gap* : $|\Pr(\hat{Y}=1 | A=0) - \Pr(\hat{Y}=1 | A=1)|$
- $|\Delta EO|$ *Equalized Odds gap* : $\max(|\Delta TPR|, |\Delta FPR|)$ (Hardt et al. 2016)
- DI *Disparate Impact ratio* : $\min_g \text{approval}_g / \max_g \text{approval}_g$. Règle US 80 % (EEOC) : $DI < 0.8 =$ présomption de discrimination indirecte.

Théorème d'impossibilité (Chouldechova 2017, Kleinberg et al. 2017)

Si les taux de base diffèrent entre groupes ($p_0 \neq p_1$), DP et EO ne peuvent être satisfaits simultanément. Il faut **choisir** le critère prioritaire.

3.2 Audit par axe

Attribut	Approval rate (par groupe)	$ \Delta DP $	$ \Delta EO $	DI
Genre	H 0.37, F 0.38	0.010	0.058	0.97
Âge	older 0.40, younger 0.27	0.125	0.066	0.69

TABLE 3 – Métriques d'équité du baseline.

Constat

Sur le **genre**, biais quasi nul après retrait de `personal_status_sex` ($DI = 0.97$). Sur l'**âge**, $|\Delta DP| = 0.125$ persiste et $DI = 0.69$ viole la règle US 80 %. C'est le **point d'alerte principal** pour un audit de conformité.

3.3 Audit intersectionnel

L'audit séparé peut masquer des biais combinés. On crée un attribut à 4 niveaux `genre_age` :

Sous-groupe	n	Approval rate	TPR
female_older	36	0.44	0.85
male_older	120	0.38	0.85
female_younger	25	0.28	0.92
male_younger	19	0.26	0.86

TABLE 4 – Taux d'octroi par sous-groupe intersectionnel.

Synthèse comparative :

Axe	$ \Delta DP $	$ \Delta EO $	DI
Genre seul	0.010	0.058	0.97
Âge seul	0.125	0.066	0.69
Intersectionnel	0.181	0.222	0.59

TABLE 5 – Écarts d'équité : agrégés vs intersectionnel.




FIGURE 2 – Approval rate par sous-groupe (gauche, ligne rouge = seuil DI 80 % local) et écarts d’équité agrégés vs intersectionnel (droite).

Surprise

Les **male_younger** ($n = 19$) ont le taux d’octroi le plus bas (0.26), **pas** les female_younger ($n = 25$, 0.28) comme l’intuition initiale le suggérait. L’intersection multiplie le biais par 1.5 par rapport à l’analyse par axe seul.

4 Atténuation des biais

4.1 Pré-traitement : reweighing (Kamiran & Calders 2012)

On répondre chaque exemple pour rendre $S \perp Y$ dans la distribution pondérée :

$$w_i = \frac{P(S = s_i) \cdot P(Y = y_i)}{P(S = s_i, Y = y_i)}$$

Méthode model-agnostic : on ré-entraîne `LogisticRegression(sample_weight=w)`, le code d’apprentissage est inchangé.

4.2 Post-traitement : seuils par groupe (Hardt et al. 2016)

Au lieu d’un seuil global τ , on calibre τ_g par groupe sensible sur la validation pour égaliser le taux de sélection cible (*Demographic Parity*). Aucun ré-entraînement requis.

4.3 Comparaison des 4 configurations

Attr.	Configuration	AUC	BalAcc	$ \Delta DP $	$ \Delta EO $
Genre	Baseline	0.785	0.669	0.010	0.058
Genre	Reweighting	0.785	0.665	0.006	0.050
Genre	Baseline + PP	0.785	0.669	0.105	0.196
Genre	Reweighting + PP	0.785	0.669	0.128	0.230
Âge	Baseline	0.785	0.669	0.125	0.066
Âge	Reweighting	0.784	0.640	0.132	0.098
Âge	Baseline + PP	0.785	0.644	0.060	0.135
Âge	Reweighting + PP	0.784	0.650	0.069	0.221

TABLE 6 – Performance et équité sur le test (PP = post-processing par seuils par groupe).




FIGURE 3 – Écarts d'équité (haut) et performance (bas) pour les 4 configurations sur les deux attributs sensibles.

Théorème d'impossibilité *en action*

Sur l'âge, le post-processing réduit $|\Delta DP|$ de **0.125 à 0.060** mais **double** $|\Delta EO|$ (0.066 vers 0.135). On ne peut pas atteindre les deux objectifs simultanément.
 Sur le genre, où le biais initial est négligeable, le post-processing introduit un biais artificiel : le seuil par groupe calibré sur 200 lignes de validation ne généralise pas au test.

5 Interprétabilité

5.1 SHAP global

Pour la régression logistique, les valeurs de Shapley admettent une expression exacte (Lundberg & Lee 2017, Corollary 1) :

$$\phi_i(x) = w_i \cdot (x_i - \mathbb{E}[x_i])$$

Implémentation via `shap.LinearExplainer`. L'importance est l'agrégation $\frac{1}{n} \sum_x |\phi_i(x)|$.




FIGURE 4 – Top 10 features par Mean |SHAP| sur le test.

Le modèle s'appuie sur des variables *financières légitimes* : `checking_status` (0.67), `credit_history` (0.49), `installment_rate` (0.39), `savings_account_bonds` (0.36). Variables démographiques absentes du top.

5.2 SHAP local : explication individuelle

Décomposition de la prédiction d'un client unique. Utile pour répondre au **droit d'explication** (RGPD article 22).




FIGURE 5 – Contributions par feature pour deux clients : haut risque (gauche, score = 0.95) et bas risque (droite, score = 0.01).

Sur le client à haut risque (vrai défaut), les features qui poussent vers défaut sont `credit_amount` (+1.18), `checking_status` (+0.81), `duration_in_month` (+0.66). Le modèle peut donc justifier sa décision auprès du client.

5.3 Détection de proxies

Question : est-ce que les autres features encodent indirectement les attributs sensibles ?

On entraîne une régression logistique `features` → `attribut sensible`. L'AUC mesure objectivement la prédictibilité de l'attribut depuis le reste.

Attribut sensible	AUC proxy	Interprétation
Genre	0.69	signal proxy modéré
Âge	0.86	très fortement reconstituable

TABLE 7 – Régression multivariée features vers attribut sensible.

Recommandation Charlotte Laclau

Retirer `age_in_years` ne suffit pas à « cacher » l'âge : il est encodé dans `housing`, `employment`, `job`... **Conserver l'attribut sensible** et l'utiliser explicitement comme pondération dans une mitigation in-processing serait théoriquement plus efficace (*fairness through awareness*, Dwork et al. 2012).

5.4 Comparaison SHAP : avant vs après retrait

On entraîne deux modèles, l'un avec les attributs sensibles, l'autre sans. On compare la redistribution de l'importance SHAP par feature.




FIGURE 6 – Top 12 features SHAP avec (bleu) vs sans (orange) attributs sensibles, et Δ SHAP (droite). Les barres vertes du panneau droit identifient les proxys absorbant l'effet retiré.

Top features absorbant l'effet : `present_employment_since` (+0.036), `telephone` (+0.022), `credit_history` (+0.020). Confirmation graphique de l'AUC proxy = 0.86.

5.5 Performance avec vs sans attributs sensibles

Mesure du coût en performance et du gain en équité du retrait :

Modèle	AUC	BalAcc	$ \Delta DP_{age} $	DI_{age}
Avec attr. sensibles	0.781	0.660	0.110	0.69
Sans attr. sensibles (baseline)	0.785	0.669	0.125	0.69

TABLE 8 – Comparaison performance et équité du retrait des attributs sensibles.




FIGURE 7 – Comparaison performance (gauche) et équité âge (droite) avec vs sans attributs sensibles.

Le retrait est cosmétique, pas correctif

Le coût en performance est négligeable ($\Delta \text{AUC} = 0.004$) et l'équité ne s'améliore pas (DI âge reste à 0.69). Sans intervention active (reweighing, post-processing, fairness through awareness), retirer la colonne sensible ne corrige pas le biais.

6 Quantification d'incertitude

6.1 Bootstrap

Choix méthodologique : sur conseil de l'enseignante, la robustesse adversariale demandée par le sujet est remplacée par une quantification d'incertitude par bootstrap (cf. cours *Robustness and Uncertainty*, G. Franchi).

On entraîne $B = 200$ régressions logistiques sur des échantillons bootstrap (Efron 1979) du train. Pour chaque modèle, on calcule les métriques sur le test, puis on agrège par quantiles 2.5 %/97.5 %.

Métrique	Moyenne	σ	IC 2.5 %	IC 97.5 %
AUC	0.764	0.019	0.723	0.795
BalAcc	0.682	0.023	0.637	0.726
$ \Delta \text{DP} $ genre	0.035	0.028	0.001	0.105
$ \Delta \text{EO} $ genre	0.089	0.044	0.017	0.176
$ \Delta \text{DP} $ âge	0.104	0.046	0.020	0.202
$ \Delta \text{EO} $ âge	0.086	0.048	0.018	0.194

TABLE 9 – Intervalles de confiance bootstrap ($B = 200$).




FIGURE 8 – Distributions bootstrap : AUC (gauche), équité genre (centre), équité âge (droite).

Lecture critique

L'IC 95 % de $|\Delta DP|$ âge va de **0.02 à 0.20**. Le biais empirique (0.125) est dans cet IC, mais l'incertitude est plus large que la valeur. Annoncer « biais $|\Delta DP| = 0.125$ » sans préciser « ± 0.10 » serait trompeur.

6.2 Intervalles de prédiction par individu

Pour chaque ligne du test, on agrège les B scores en moyenne et écart-type. Une forte variance signale un client **sur la frontière de décision**.




FIGURE 9 – Intervalles de prédiction par individu (gauche) et incertitude vs score (droite). La forme parabolique confirme que l'incertitude est maximale au milieu (cas frontières).

Les 10 individus les plus incertains ont des écarts-type bootstrap de 0.20–0.24. Le candidat le plus incertain (id = 236) a un score moyen de 0.39 mais un IC de $[0.03, 0.85]$: selon le tirage du jeu d'entraînement, ce client serait soit accepté, soit refusé. Une expertise humaine est recommandée pour ces cas.

7 Tableau de bord récapitulatif




FIGURE 10 – Synthèse des métriques clés du baseline. Ligne pointillée rouge = seuil DI 80 % (EEOC).

Point d'alerte unique : $DI_{\text{âge}} = 0.69$, sous le seuil légal US 0.8 (règle EEOC). C'est l'élément à signaler prioritairement dans un audit de conformité. Tout le reste (performance, équité genre, calibration) est dans les marges acceptables.

8 Conclusion

8.1 Résultats principaux

1. **Modèle.** Régression logistique L2, $AUC = 0.785$, $BalAcc = 0.669$. Convergence en 6 itérations.
2. **Forte présence de proxies multivariés** (approche Charlotte). La régression **features** $\rightarrow$ **âge** atteint $AUC = 0.86$; **features** $\rightarrow$ **genre** atteint $AUC = 0.69$. Retirer les attributs sensibles ne les cache pas, leur effet se redistribue (vérifié visuellement par SHAP avant/après, voir §5.4 et §5.5 dans le notebook).
3. **Discrimination sur l'âge plus marquée que sur le genre.** $|\Delta DP|_{\text{âge}} = 0.125$, $DI = 0.69$ (sous seuil légal US 0.8). Audit intersectionnel : $|\Delta DP| = 0.181$ ($1.5\times$ plus fort) ; les jeunes hommes ($n = 19$) sont les plus défavorisés.
4. **Théorème d'impossibilité confirmé empiriquement.** PP réduit $|\Delta DP|_{\text{âge}}$ (0.125 vers 0.060) mais double $|\Delta EO|$ (0.066 vers 0.135).
5. **Significativité statistique faible.** Bootstrap : IC 95 % de $|\Delta DP|_{\text{âge}} = [0.02, 0.20]$. Sur 1000 lignes, les conclusions sur l'équité doivent être nuancées par cette incertitude.
6. **Le retrait des attributs n'est pas une mitigation.** AUC quasi inchangée (0.785 sans vs 0.781 avec) et $DI_{\text{âge}}$ reste à 0.69 dans les deux cas. Une intervention active est nécessaire.

8.2 Choix méthodologiques

- Robustesse adversariale du sujet remplacée par **bootstrap** (conseil de l'enseignante).
- Coût métier UCI ($5 \cdot FN + 1 \cdot FP$) pour ancrer le choix de seuil dans la réalité bancaire.

8.3 Limites

- **Petit dataset** (1000 lignes, test 200) : IC 95 % des écarts d'équité dépassent 0.15.
- **Approche linéaire** : capacité limitée à capturer des interactions non linéaires.
- **Reweighting simple** : on ne traite qu'une dépendance binaire $S \perp Y$. Des méthodes plus avancées (fairlearn.ExponentiatedGradient, transport optimal) pourraient mieux gérer les contraintes.
- **Pas de fairness through awareness implémentée**, malgré l' $AUC_{\text{proxy}} = 0.86$ qui la justifierait. Piste pour une suite.

8.4 Outils d'assistance utilisés

Conformément à l'exigence du sujet, des LLM (Claude, GPT) ont été utilisés pour : aide à la rédaction du code (pipeline sklearn, intégration fairlearn/shap), structuration du notebook et du rapport. Les décisions méthodologiques (choix des métriques, interprétation, conception du bootstrap) ont été prises et discutées en équipe.

Références

Références

- [1] A. Chouldechova, *Fair prediction with disparate impact*, Big Data 5(2), 2017. arXiv:1703.00056.
- [2] J. Kleinberg, S. Mullainathan, M. Raghavan, *Inherent trade-offs in the fair determination of risk scores*, ITCS 2017. arXiv:1609.05807.
- [3] M. Hardt, E. Price, N. Srebro, *Equality of Opportunity in Supervised Learning*, NeurIPS 2016. arXiv:1610.02413.
- [4] F. Kamiran, T. Calders, *Data preprocessing techniques for classification without discrimination*, KAIS 33(1), 2012. doi:10.1007/s10115-011-0463-8.
- [5] C. Dwork et al., *Fairness through awareness*, ITCS 2012. arXiv:1104.3913.

- [6] R. K. E. Bellamy et al., *AI Fairness 360*, IBM, 2018. arXiv:1810.01943.
- [7] S. Bird et al., *Fairlearn : a toolkit for assessing and improving fairness in AI*, Microsoft 2020. fairlearn.org.
- [8] S. Lundberg, S.-I. Lee, *A Unified Approach to Interpreting Model Predictions*, NeurIPS 2017. arXiv:1705.07874.
Linear SHAP : Corollary 1.
- [9] B. Efron, *Bootstrap methods*, Annals of Statistics 7(1), 1979. doi:10.1214/aos/1176344552.
- [10] B. Lakshminarayanan et al., *Deep Ensembles*, NeurIPS 2017. arXiv:1612.01474.
- [11] F. Pedregosa et al., *Scikit-learn : Machine Learning in Python*, JMLR 12, 2011. jmlr.org.
- [12] Cours IA708, F. d'Alché-Buc, C. Laclau, G. Franchi, Télécom Paris.